

Эконометрика, НИУ ВШЭ

Составили эконометрессы Максимовская Анастасия, Перевышина Татьяна, Ситникова Арина, а также Пилипейко Роман

1.0 Линейная регрессия с одной объясняющей переменной (парная регрессия)


Линейная регрессионная модель имеет следующий вид:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i, \quad i = 1, ..., n$$

1.1 Метод наименьших квадратов (OLS) для нахождения оценок коэффициентов парной регрессии

Зачем он нужен? Для нахождения оценок коэффициентов $\hat{\beta}_1, \hat{\beta}_2$

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$$
$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$
$$\hat{\beta}_2 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{sCov(x, y)}{sVar(x)}$$



$$sCorr(x; y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Проекция y на $Lin(1; x)$: $\hat{y} = \hat{\beta}_1 \mathbb{1} + \hat{\beta}_2 x^c$

Проекция x и y на $Lin\perp(\mathbb{1})$: $x^c = x - \bar{x}\mathbb{1} = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}, y^c = y - \bar{y}\mathbb{1} = \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}$

Проекция x и y на $Lin\perp(\mathbb{1})$: $x^c = x - \bar{x}\mathbb{1} = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}$

Проекция y^c на $Lin(x^c)$: $\beta_2 x^c = \hat{y} - \bar{y}\mathbb{1}$

Проекция x^c на $Lin(\mathbb{1})$: 0

Проекция x^c на $Lin\perp(\mathbb{1})$: x^c

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2 = ESS + RSS = |y - \bar{y}\mathbb{1}|^2 = AB^2 = y^c{}^2$$
$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = AC^2$$
$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2 = BC^2$$
$$R^2 = \frac{ESS}{TSS} = \frac{sVar(\hat{y})}{sVar(y)} = \frac{AC^2}{AB^2} = \cos(\varphi') = sCorr^2(y; \hat{y}) = sCorr^2(y; x)$$

1.2 Теорема Гаусса - Маркова для случая парной регрессии

Зачем она нужна? Для получения дополнительной информации о характеристиках распределения оценок $\hat{\beta}_1, \hat{\beta}_2$

Теорема 1.2 Гаусса - Маркова для случая парной регрессии

Если для модели $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i + \varepsilon_i, i = 1, ..., n$ выполняются следующие условия:

- 1) Строится регрессия y на x
- 2) Не все x_i равны между собой
- 3) Математическое ожидание от любой ошибки регрессии равно 0
- 4) Дисперсия от любой ошибки регрессии равна σ_ε^2
- 5) $Cov(\varepsilon_i, \varepsilon_j) = 0$ - отсутствие автокорреляции,

то МНК - оценки $\hat{\beta}_1$ и $\hat{\beta}_2$ являются *BLUE*

Best (наилучшие)	для любых $\hat{\beta}_i$ верно: $MSE(\hat{\beta}_i) \leq MSE(\beta_i)$
Linear (линейные)	Оценки линейные по y
Unbiased (несмещенные) Estimator (оценки)	$E(\hat{\beta}_i) = \beta_i$

Утверждение 1.2 Если условия теоремы Гаусса - Маркова выполнены, то дисперсии МНК оценок:

$$Var(\hat{\beta}_1) = \sigma_\varepsilon^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \quad Var(\hat{\beta}_2) = \frac{\sigma_\varepsilon^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

а их ковариация:

$$Cov(\hat{\beta}_1, \hat{\beta}_2) = -\frac{\bar{x} \sigma_\varepsilon^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

1.3 Предположение о нормальном распределении случайной ошибки в рамках классической линейной регрессии

Утверждение 1.3.1 Если верно, что $\varepsilon_i \sim N(0, \sigma_\varepsilon^2), i = 1...n$, то МНК-оценки коэффициентов парной регрессии также имеют нормальное распределение, причём $\hat{\beta}_1 \sim N(\beta_1, Var(\hat{\beta}_1)), \hat{\beta}_2 \sim N(\beta_2, Var(\hat{\beta}_2))$.

Утверждение 1.3.2 $\hat{\sigma}_\varepsilon^2 = \frac{RSS}{n-2}$ является несмещённой оценкой для σ_ε^2 .

Утверждение 1.3.3 $\frac{RSS}{\hat{\sigma}_\varepsilon^2} \sim \chi_{n-2}^2$ для парной регрессии.

Утверждение 1.3.4 Оценки $\hat{\beta}_1$ и $\hat{\sigma}_\varepsilon^2, \hat{\beta}_2$ и $\hat{\sigma}_\varepsilon^2$ являются независимыми.

1.3.1 Проверка гипотезы о конкретном значении коэффициентов парной регрессии

$$H_0 : \beta_2 = \beta_2^0$$
$$H_a : \beta_2 \neq \beta_2^0$$

Если $|t = \frac{\hat{\beta}_2 - \beta_2^0}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| > t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 отвергается в пользу гипотезы H_a .

Если значение $|t = \frac{\hat{\beta}_2 - \beta_2^0}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| < t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 не отвергается.

1.3.2 Проверка гипотезы о значимости коэффициентов парной регрессии

$$H_0 : \beta_2 = 0$$
$$H_a : \beta_2 \neq 0$$

Если значение $|t = \frac{\hat{\beta}_2}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| > t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 отвергается, значит, β_2 значим.

Если значение $|t = \frac{\hat{\beta}_i}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| < t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 не отвергается, значит, β_2 не значим.

Доверительный интервал

$$[\hat{\beta}_2 - t^{cr} \sqrt{\hat{Var}(\hat{\beta}_2)}; \hat{\beta}_2 + t^{cr} \sqrt{\hat{Var}(\hat{\beta}_2)}]$$

Если доверительный интервал включает в себя нуль, то этот коэффициент не значим, при уровне значимости α .

В обоих случаях t^{cr} рассчитывается на уровне значимости $\alpha/2$ с $n - 2$ степенями свободы.

1.3.3 Прогнозирование по модели парной регрессии и его точность

Доверительный интервал для среднего прогноза

$$\hat{Var}(\hat{y}_{n+1}) = \hat{Var}(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1}) = \hat{\sigma}_\varepsilon^2 [1 + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}]$$
$$P(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} - t_{\alpha/2, n-2} \sqrt{\hat{Var}(\hat{y}_{n+1})} \leq E(y_{n+1} | x = x_{n+1}) \leq \hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + t_{\alpha/2, n-2} \sqrt{\hat{Var}(\hat{y}_{n+1})}) = 1 - \alpha$$

Доверительный интервал для индивидуального прогноза

$$\hat{Var}(y_{n+1}) = \hat{Var}(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + \varepsilon_{n+1}) = \hat{\sigma}_\varepsilon^2 [1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}]$$
$$P(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} - t_{\alpha/2, n-2} \sqrt{\hat{Var}(y_{n+1})} \leq y_{n+1} \leq \hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + t_{\alpha/2, n-2} \sqrt{\hat{Var}(y_{n+1})}) = 1 - \alpha$$

Доверительный интервал дисперсии ошибок регрессии

$$P(\frac{RSS}{\chi_{\alpha/2, n-2}^2} \leq \sigma_\varepsilon^2 \leq \frac{RSS}{\chi_{1-\alpha/2, n-2}^2}) = 1 - \alpha$$

1.3.4 Проверка гипотезы о нормальности распределения

Критерий Колмогорова - Смирнова

Когда используется? Выборка состоит из достаточно большого количества наблюдений n

$$H_0 : F(t) = G(t) \text{ для любого } t$$
$$H_a : F(t) \neq G(t) \text{ при некотором } t$$

С использованием таблиц:


$$J = \frac{mn}{d} \max_{-\infty < t < \infty} |F_m(t) - G_n(t)|$$

где $F_m(t)$ и $G_m(t)$ – эмпирические функции распределения для выборок $x_1, ..., x_m$ и $y_1, ..., y_n$, а именно:

$$F_m(t) = \frac{\text{Число элементов в первой выборке, не превышающих } t}{m}$$
$$G_n(t) = \frac{\text{Число элементов во второй выборке, не превышающих } t}{n}$$

d – НОД(m, n), m и n – общее количество элементов в первой и второй выборке соответственно.

Статистика имеет специальное распределение D при верной H_0 :



Тест Харке - Бера Когда используется? Выборка состоит из достаточно большого количества наблюдений n

$$H_0 : s = 0, k = 3$$
$$H_a : s \neq 0, k \neq 3$$

Тестовая статистика:

$$JB = \frac{n}{6} (s^2 + \frac{1}{4} (k - 3)^2) \sim \chi_2^2$$

Коэффициент асимметрии: $s = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^3}{\bar{\sigma}^3}, \bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

Для симметричных распределений, в том числе нормального, этот показатель равен нулю.

Коэффициент эксцесса: $k = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^4}{\bar{\sigma}^4}$

Для нормального распределения этот показатель равен 3.

Если $JB > \chi_2^2$ при выбранном уровне значимости, то гипотеза отвергается.

Тест Шапиро - Уилка

Когда используется? Выборка состоит из небольшого количества наблюдений n

$$H_0 : x_1, ..., x_n - \text{выборка из нормального распределения}$$
$$H_a : x_1, ..., x_n - \text{выборка не из нормального распределения}$$

Тестовая статистика:

$$W = \frac{(\sum_{i=1}^n \alpha_{(i)} x_i)^2}{\sum_{i=1}^n (x_{(i)} - \bar{x})^2} \sim W_\alpha$$

Вектор коэффициентов: $\alpha_{(i)} = \frac{m^i V^{-1}}{m^i V^{-1} - 1}$

m – вектор математических ожиданий порядковых статистик нормального распределения;
 V – ковариационная матрица этих порядковых статистик размера $n \times n$.

Для небольших n коэффициенты $\alpha_{(i)}$ берутся из таблиц.

Если $W < W_\alpha$, то гипотеза H_0 отвергается.

$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln y_i, & \lambda = 0 \end{cases}$$

4. Вычисляем тестовую статистику:

$$\chi^2 = nR_e^2 \sim \chi_{m-1}^2$$

где *m* — число оцениваемых во вспомогательной регрессии коэффициентов.

5. Если Р-значение < α, гипотеза *H*₀ о гомоскедастичности отвергается.

Эта же гипотеза (о равенстве нулю всех коэффициентов α_{*i*}, γ_{*i*}, δ_{*ij*}) может быть проверена с помощью *F*-статистики. Если значение тестовой статистики превышает критическое, то нулевая гипотеза о гомоскедастичности отвергается.

- Тест Бройша - Пагана**

Привлекательной чертой теста Уайта является его универсальность, однако он не дает указания на функциональную форму гетероскедастичности. Если может иметь место и более специфический вид зависимости, в том числе и от не включенных в модель факторов *z*₁, ..., *z*_{*p*}, используют тест Бройша - Пагана. Альтернативная гипотеза для него имеет вид:

$$H_a: \sigma_i^2 \sim f(z_1, ..., z_p)$$

причем *f* предполагается некоторой гладкой функцией, но ее вид не конкретизируется.

Тест Бройша - Пагана состоит из следующих шагов (первые два шага совпадают с предыдущими тестами):

3. Строим оценку для дальнейшей нормировки квадратов остатков регрссии:

$$\hat{\sigma}_i^2 = \frac{\sum_{i=1}^k e_i^2}{n}.$$

4. Оцениваем параметры регрессии

$$\frac{e_i^2}{\hat{\sigma}_i^2} = \gamma_1 + \gamma_2 z_{i2} + ... + \gamma_p z_{ip} + \varepsilon_i$$

и вычисляем для нее *ESS*.

5. Рассчитываем тестовую статистику:

$$\chi^2 = \frac{ESS}{2} \sim \chi_p^2$$

6. Если Р-значение < α, гипотеза *H*₀ о гомоскедастичности отвергается.

7.2 Оценивание параметров множественной линейной регрессии в условиях гетероскедастичности ошибок

- Изменение модели с линейной формы на логарифмическую может привести к тому, что в тестах на гетероскедастичность не будет отвергаться основная гипотеза о гомоскедастичности.

- Если дисперсии всех ошибок заранее известны, то для устранения гетероскедастичности достаточно было бы оценить исходное уравнение, поделенное почленно на стандартные отклонения ошибок

$$\frac{y_i}{\sigma_i} = \beta_1 \frac{1}{\sigma_i} + \beta_2 \frac{x_{i2}}{\sigma_i} + ... + \beta_k \frac{x_{ik}}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}, i = 1, ..., n$$

и оценить регрессию с новыми факторами

$$y_i^* = \frac{y_i}{\sigma_i}, 1_i^* = \frac{1}{\sigma_i}, x_{ij}^* = \frac{x_{ij}}{\sigma_i}, \varepsilon_i^* = \frac{\varepsilon_i}{\sigma_i}, j = 1, .., k, i = 1, ..., n$$

В уравнении *y*_{*i*}^{*} = β₁1_{*i*}^{*} + β₂*x*_{*i2*}^{*} + ... + β_{*k*}*x*_{*ik*}^{*} + ε_{*i*}^{*} все ошибки имеют одну и ту же дисперсию, равную единице, поскольку Var(ε_{*i*}^{*}) = Var(

ε

i

σ

i

) =

1

σ

i

2

 Var(ε_{*i*}) = 1. Тогда МНК-оценки коэффициентов в регрессии с преобразованными данными имеют вид

$$\hat{\beta }^{\ast }=(X^{\ast T}X^{\ast })^{-1}(X^{\ast T}Y^{\ast })$$

Эту оценку можно выразить через исходные данные

$$\hat{\beta }^{\ast }=(X^TX\Omega ^{-1}X)^{-1}(X^T\Omega ^{-1}Y)$$

$$\mathrm{где}\;\Omega =\left[\begin{array}{ccc}\sigma _1^2&\ldots &0\\ 0&\ldots &0\\ 0&\ldots &\sigma _n^2\end{array}\right]$$

Данная оценка называется оценкой **взвешенного МНК**. Ковариационная матрица оценок имеет вид *V*(β
^
) = (*X*^{*T*}Ω^{−1}*X*)^{−1}

- Наиболее распространенным способом коррекции гетероскедастичности в общем виде является использование оценок Уайта для дисперсий коэффициентов:

$$\hat{V}(\hat{\beta}) = \frac{1}{n}(\frac{1}{n}X^TX)^{-1}(\frac{1}{n}\sum_{i=1}^ne_i^2x_ix_i^T)(\frac{1}{n}X^TX)^{-1}$$

где *x*_{*i*} – i-я строка матрицы *X*, *i* = 1, ..., *n*

- Для выявления гетероскедастичности рекомендуется проверить выборку на наличие вертикальных выбросов.

- Можно также рассмотреть стандартизированные остатки в двух формах:

$$e_i^* = \frac{e_i}{\hat{\sigma}_\varepsilon \sqrt{1-h_{ii}}}$$

$$e_i^* = \frac{e_i}{\hat{\sigma}_{\varepsilon(-i)}\sqrt{1-h_{ii}}},$$

где *e* = (*I* − *H*)ε,

H = *X*(*X*^{*'*}*X*)^{−1}*X*^{*'*} – матрица-шляпница,

Y
^

=
H
Y
,

{\displaystyle {\hat {Y}}=HY,}

y
^

i

=

∑

n

i
=
1

h

i
i

y

i

,

h

i
i

– диагональный элемент *h*,

Var(*e*) = (*I* − *H*)σ_ε².

Если |*e*_{*i*}^{*}| > 2, то это выброс.

При обнаружении выбросов можно:

- Оценить без них;
- Создать фиктивную переменную на выброс;
- Применить робастное (устойчивое к выбросам) оценивание.

В чем заключается робастное оценивание?

Медианная регрессия:

R
S
S
=

∑

i
=
1

n

|

e

i

|
→
min

β

{\displaystyle RSS=\sum _{i=1}^n|e_{i}|\rightarrow \min _{\beta }}

Р-регрессия:

ρ
{

ε

i

σ

i

}
→
min

{\displaystyle \rho \left\{{\frac {\varepsilon _{i}}{\sigma _{i}}}\right\}\rightarrow min}

 тождественно равно

∑

i
=
1

n

w

i

e

i

2

→
min

{\displaystyle \sum _{i=1}^nw_{i}e_{i}^{2}\rightarrow min}

Функция потерь Хьюбера:

$$\rho (u)=\left\{\begin{array}{l}\frac{1}{2}u^2,|u|\leq c,\\c|u|-\frac{1}{2}c^2,|u|>c\end{array}\right.$$

Веса корректируются на каждом шаге по формуле *u*_{*i*} =

1

ε

i

2

ρ
(

ε

i

σ

i

)

. Корректировка заканчивается, когда веса почти не меняются. Берутся последние значения β.

8.0 Метод максимального правдоподобия

Метод максимального правдоподобия, в отличие от МНК, работает при более слабых предположениях, чем выполнение условий ТГМ. Если *x*₁, ..., *x*_{*n*} – реализации случайных величин *X*₁, ..., *X*_{*n*}, то необходимо максимизировать функцию правдоподобия:

$$L(x_1,...,x_n|\theta)=P(X_1=x_1,...,X_n=x_n|\theta)\rightarrow max_{\theta },$$

где **θ** – вектор оцениваемых параметров.

Однако на практике чаще ищут максимум логарифмической функции правдоподобия:

$$l(x_1,...,x_n|\theta)=\ln L(x_1,...,x_n|\theta)$$

Для случая непрерывных величин *X*₁, ..., *X*_{*n*} в качестве функции правдоподобия выбирается плотность их совместного распределения в точке *x*₁, ..., *x*_{*n*}:

$$L(x_1,...,x_n|\theta)=f(x_1,...,x_n|\theta)$$

8.1 Свойства МL-оценок

1. Инвариантность

Если

θ

ML

 – МL-оценка параметра **θ** и *g*(·) – непрерывная функция, то *g*(

θ

ML

) является МL-оценкой параметра *g*(**θ**).

2. Состоятельность

3. Асимптотическая нормальность

При *n* → ∞ оценка вектора параметров имеет нормальное распределение:

$$\hat{\theta }_{ML}\overset{as}{\approx }N(\theta ;I^{-1}(\theta)),$$

где *I*(**θ**) – информационная матрица Фишера.

4. Асимптотическая эффективность

8.2 Проверка гипотез

Следующие три теста позволяют проверить гипотезу об ограничениях:

$$H_0: \begin{cases} g_1(\theta)=0\\ ...\\ g_r(\theta)=0 \end{cases} \qquad H_a: \begin{cases} g_1(\theta)\neq 0\\ ...\\ g_r(\theta)\neq 0 \end{cases}$$

- Тест Вальда

$$W=g^T(\hat{\theta }_{ur})[\frac{\partial g}{\partial \theta }(\hat{\theta }_{ur})I^{-1}(\hat{\theta }_{ur})\frac{\partial g^T}{\partial \theta }(\hat{\theta }_{ur})]^{-1}g(\hat{\theta }_{ur})\sim \chi _r^2$$

- Тест отношения правдоподобия (LR-тест)

$$LR=-2(l(\hat{\theta }_r)-l(\hat{\theta }_{ur}))\sim \chi _r^2$$

- Тест множителей Лагранжа (LM-тест)

$$LM=\frac{\partial l}{\partial \theta }(\hat{\theta }_r)^TI^{-1}(\hat{\theta }_r)\frac{\partial l}{\partial \theta }(\hat{\theta }_r)\sim \chi _r^2$$

Во всех случаях *r* – количество ограничений.

9.0 Модели бинарного выбора

В случаях, когда объясняемая переменная *y* – бинарная (принимает значения 0 или 1), также можно использовать линейную модель *y*_{*i*} = β₁ + β₁*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*} + ε_{*i*}.

Пусть *p*_{*i*} = *P*(*y*_{*i*} = 1), *i* = 1, ..., *n*. Тогда *P*(*y*_{*i*} = 0) = 1 − *p*_{*i*} и верно, что *E*(*y*_{*i*}) = *P*(*y*_{*i*} = 1) × 1 + *P*(*y*_{*i*} = 0) × 0. При этом также верно, что *E*(*y*_{*i*}) = β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*}. Отсюда получается модель линейной вероятности:

$$P(y_i=1)=\beta _1+\beta _2x_{i2}+...+\beta _kx_{ik}$$

Недостатки модели линейной вероятности

- Оцененное значение вероятности может не принадлежать отрезку [0; 1].
- Ошибки не будут распределены нормально, т.к. ε_{*i*} тоже принимает значения 0 или 1. Следовательно, привычные *t*-статистики для проверки гипотез использовать нельзя.
- Дисперсии ошибок равны

(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*})(1 − (β₁ + β₂*x*_{2*i*} + ... + β_{*k*}*x*_{*ik*})), *i* = 1, ..., *n*,

т.е. имеет место гетероскедастичность, МНК-оценки не будут эффективными.

9.1 Логит и пробит модели

Для исправления данных недостатков используют модели бинарного выбора:

$$P(y_i=1)=F(z_i),\quad z_i=\beta _1+\beta _2x_{i2}+...+\beta _kx_{ik},\quad i=1,...,n,$$

где *F* – сигмоидная функция, принимающая значения на интервале [0;1]. Предположим, что существует *y*_{*i*}^{*} = β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*} + ε_{*i*}, *i* = 1, ..., *n*, где ошибки ε_{*i*}, ..., ε_{*n*} независимы и имеют одну и ту же симметричную функцию плотности *f*(*x*) = *f*(−*x*), функцию распределения *F*(·), *E*(ε_{*i*}) = 0, *Var*(ε_{*i*}) = σ_ε².

Величины *y*_{*i*} и *y*_{*i*}^{*} связаны следующим образом:

$$\begin{cases} y_i=1, y_i^*\geq 0,\\ y_i=0, y_i^*< 0. \end{cases}$$

Тогда *P*(*y*_{*i*} = 1) = *P*(*y*_{*i*}^{*} ≥ 0) = *P*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*} + ε_{*i*} ≥ 0) = = *P*(ε_{*i*} ≥ −(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*})).

В силу симметрии функции плотности *f* относительно нуля

$$P(y_i=1)=P(\varepsilon _i\leq \beta _1+\beta _2x_{i2}+...+\beta _kx_{ik})$$

Обозначим за *F*(·) функцию распределения нормированных ошибок

ε

i

σ

ε
. Отсюда можно выразить формулу для моделей бинарного выбора:

$$P(y_i=1)=F(\frac{\beta _1}{\sigma _\varepsilon }+\frac{\beta _2}{\sigma _\varepsilon }x_{i2}+...+\frac{\beta _k}{\sigma _\varepsilon }x_{ik})$$

Наиболее употребимые в эконометрических моделях функции:

- Логит-модель

F(*z*) =

1

1
+

e

−
z

 – логистическая функция

f(*z*) =

e

−
z

(
1
+

e

−
z

)

2
- Пробит-модель

F(*z*) =

1

√
2
π

∫

z

−
∞

e

−

t

2

/
2

d
t

f(*z*) =

1

√
2
π

e

−

z

2

/
2

9.2 Оценивание параметров моделей бинарного выбора

Для оценки параметров моделей бинарного выбора используется ММП. Функция правдоподобия выглядит следующим образом:

L(β) = ∏_{*y*_{*i*} = 1} *F*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*}) ∏_{*y*_{*i*} = 0} (1 − *F*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*})) =

= ∏_{*i* = 1}^{*n*} (*F*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*}))^{*y*_{*i*}} (1 − *F*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*}))^{1−*y*_{*i*}}

Логарифмическая функция правдоподобия:

l(β) = ln *L*(β) = ∑_{*i* = 1}^{*n*} [*y*_{*i*} ln *F*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*}) + (1 − *y*_{*i*}) ln(1 − *F*(β₁ + β₂*x*_{*i2*} + ... + β_{*k*}*x*_{*ik*}))]

Если *F*(*z*) = Λ(*z*) =

1

1
+

e

−
z

, то для логит-моделей можно вывести следующую формулу:

$$\sum_{i=1}^n[y_i-\Lambda(\beta_1+\beta_2x_{i2}+...+\beta_kx_{ik})]x_{ij}=0,\quad j=0,...,k$$

9.3 Интерпретация результатов оценивания логит- и пробит- моделей

При использовании ММП дисперсии оценок параметров являются соответствующими диагональными элементами матрицы *I*^{−1}(**θ**). Для моделей бинарного выбора можно проверить гипотезу:

$$\begin{matrix} H_0: \beta_j=0\\ H_a: \beta_j\neq 0 \end{matrix}$$

При

θ
^

as

{\displaystyle {\hat {\theta }}\overset {as}{}{}}

 тестовая статистика рассчитывается как:

$$z=\frac{\hat{\beta }_j}{\sqrt {\mathrm {Var} (\hat{\beta }_j)}}$$

Если |*z*| ≥ *z*_{α/2}, где α - выбранный уровень значимости, то гипотеза *H*₀ о незначимости отвергается. Однако интерпретировать можно только знак оценки коэффициента (если

β
^

j

>
0,

 то при увеличении *x*_{*j*} вероятность


При автокорреляции оценки МНК будут несмещенными, но неэффективными. Стандартные ошибки коэффициентов будут недооценены, t -статистики будут слишком большие.

11.1 Причины возникновения автокорреляции

- Пропуск существенной переменной;
- Инертность макроэкономических данных;
- Сглаживание первоначальных данных;
- Неправильная форма модели;

11.2 Способы обнаружения автокорреляции

Первый способ: Графический.



На картинке (а) изображен график нормальных остатков по времени. На всех остальных изображены графики остатков с различными видами автокорреляции.

Второй способ: Проведение тестов на выявление автокорреляции.

- Тест серий.**

Для проведения теста выписываются знаки остатков по очереди, при этом *серия* – набор остатков одного знака.
Дано: *T* – общее число наблюдений, *N*₁ – число положительных остатков, *N*₂ – число отрицательных остатков, *K* – число серий.

*H*₀ : нет автокорреляции

*H*_{*a*} : положительная автокорреляция/отрицательная автокорреляция

Если *K* ≤ *K*_{*min*} – автокорреляция положительная;

Если *K* ≥ *K*_{*max*} – автокорреляция отрицательная.

При этом *K*_{*min*} = min{*N*₁; *N*₂} – 1, *K*_{*max*} = max{*N*₁, *N*₂} + 1.

Если *T* > 40, справедливо следующее:

- Тест Дарбина - Уотсона.**

В этом тесте используется особая статистика, которая так и называется – статистика Дарбина - Уотсона (DW-статистика). Рассчитывается она следующим образом:

D
W
=

∑

t
=
2

T

(

e

t

−

e

t
−
1

)

2

∑

t
=
1

T

e

t

2

}
≈
2
−
2
ρ
,
|
ρ
|
<
1
⇒
0
<
2
−
2
ρ
<
4

{\displaystyle DW={\frac {\sum _{t=2}^{T}(e_{t}-e_{t-1})^{2}}{\sum _{t=1}^{T}e_{t}^{2}}}\approx 2-2\rho ,\;|\rho |<1\Rightarrow 0<2-2\rho <4}

Тестирование на автокорреляцию с помощью DW-статистики проводит-ся по следующей гипотезе:

*H*₀ : *ρ* = 0, т.е. отсутствие автокорреляции

*H*_{*a*} : *ρ* > 0 ЛИБО *ρ* < 0

Для проведения расчетов используются две вспомогательные пере-менные *d*_{*u*} и *d*_{*L*}, значения которых заданы таблично. При этом: 0 < *d*_{*L*} < *d*_{*u*} < 2.

При *H*_{*a*} : *ρ* > 0 (положительная автокорреляция):

1)*DW* < *d*_{*L*} ⇒ Присутствует положительная автокорреляция.

2)*d*_{*L*} ≤ *DW* ≤ *d*_{*U*} ⇒ Определить наличие автокорреляции невозмож-но.

3)*DW* > *d*_{*U*} ⇒ Положительная автокорреляция отсутствует.

При *H*_{*a*} : *ρ* < 0 (отрицательная автокорреляция):

1)*DW* > (4 – *d*_{*L*}) ⇒ Присутствует отрицательная автокорреляция.

2)(4 – *d*_{*U*}) ≤ *DW* ≤ (4 – *d*_{*L*}) ⇒ Определить наличие автокорреляции невозможно.

3)*DW* < (4 – *d*_{*U*}) ⇒ Отрицательная автокорреляция отеутствует.

- Тест Бройша - Годффри.**

В отличие от предыдущих тестов, этот тест используется для выяв-ления автокорреляции более 1-го порядка.

Пусть *y*_{*t*} = *β*₁+*β*₂*x*_{*t*}+*ε*_{*t*}, при этом

ε

t

=

ρ

1

ε

t
−
1

+

ρ

2

ε

t
−
2

+
.
.
.
+

ρ

p

ε

t
−
p

+

u

t

{\displaystyle \varepsilon _{t}=\rho _{1}\varepsilon _{t-1}+\rho _{2}\varepsilon _{t-2}+...+\rho _{p}\varepsilon _{t-p}+u_{t}}

 Гипотеза выглядит следующим образом:

*H*₀ : *ρ*₁ = ... = *ρ*_{*p*} = 0 (автокорреляции в остатках нет)

*H*_{*a*} : ∃*ρ*_{*j*} ≠ 0, *j* = 1 ... *T* (автокорреляция есть)

Шаг 1. Оценивается начальная модель и рассчитывается ряд остатков.

Шаг 2. Оценивается дополнительная модель:

e

t

=

β

1

+

β

2

x

t

+

r

1

e

t
−
1

+

r

2

e

t
−
2

+
.
.
.
+

r

p

e

t
−
p

+

u

t

{\displaystyle e_{t}=\beta _{1}+\beta _{2}x_{t}+r_{1}e_{t-1}+r_{2}e_{t-2}+...+r_{p}e_{t-p}+u_{t}}

Шаг 3. Для дополнительной модели рассчитывается *R*_{*e*}², а затем стати-стика вида:

χ

2

=
T
×

R

e

2

∼

χ

p

2

{\displaystyle \chi ^{2}=T\times R_{e}^{2}\sim \chi _{p}^{2}}

Если значение статистики превышает критическое при выбранном уровне значимости, основная гипотеза об отсутствии автокорреляции отвергается.

11.3 Что делать, если обнаружилась автокорреляция?

- Переход к взвешенным разностям.**
- Пусть модель выглядит как *y*_{*t*} = *β*₁+*β*₂*x*_{*t*}+*ε*_{*t*}.
- Шаг 1.* Необходимо получить оценку параметра *ρ*. Например, можно оценить его из статистики Дарбина-Уотсона по формуле

ρ
^

=
1
−

d
^

2

{\displaystyle {\hat {\rho }}=1-{\frac {d}{2}}}

.
- Шаг 2.* Далее исходное уравнение сдвигается на шаг назад и домножа-ется на *ρ*:

ρ

y

t
−
1

=
ρ

β

1

+
ρ

β

2

x

t
−
1

+

ε

t
−
1

{\displaystyle \rho y_{t-1}=\rho \beta _{1}+\rho \beta _{2}x_{t-1}+\varepsilon _{t-1}}

Шаг 3. Вычесть из исходного уравнения преобразованное. Получаем:

y

t

−
ρ

y

t
−
1

=

β

1

(
1
−
ρ
)
+

β

2

(

x

t

−
ρ

x

t
−
1

)
+

ε

t

−
ρ

ε

t
−
1

{\displaystyle y_{t}-\rho y_{t-1}=\beta _{1}(1-\rho)+\beta _{2}(x_{t}-\rho x_{t-1})+\varepsilon _{t}-\rho \varepsilon _{t-1}}

Теперь автокорреляция отсутствует, но теряется одно наблюдение.

- Поправка Прайса - Уинстона.**
- Заменяем первые наблюдения:

y

1

∗
=

y

1

√
1
−

ρ

2

,

x

1

∗
=

x

1

√
1
−

ρ

2

{\displaystyle y_{1}^{*}=y_{1}{\sqrt {1-\rho ^{2}}},\;\;x_{1}^{*}=x_{1}{\sqrt {1-\rho ^{2}}}}

12.0 Временные ряды

Временной ряд – ряд некоторых числовых величин, измеренных в последовательные моменты времени.

{

y

t

}

+
∞

−
∞

,

t
=
1
.
.
.
T

{\displaystyle \{y_{t}\}_{-\infty }^{+\infty },\;t=1\ldots T}

Ключевым отличием временных рядов от пространственных выборок является то, что наблюдения строго упорядочены по времени, невозможно произвольно менять их местами, а также выкидывать из выборки.

12.1 Стационарные процессы

Утверждение 12.1

{

y

t

}

{\displaystyle \{y_{t}\}}

 называется стационарным в узком смы-сле, если распределение *y*₁₁, *y*₁₂, *y*₁₃, . . . , *y*_{1*k*} совпадает с распределением *y*_{11+*s*}, *y*_{12+*s*}, *y*_{13+*s*}, . . . , *y*_{1*k*+*s*}

∀

t

1

.
.
.

t

k
+
s

,

s
>
0
,

k
>
0

{\displaystyle \;\;\;\;\;\forall t_{1}\ldots t_{k+s},\;s>0,k>0}

Утверждение 12.2

{

y

t

}

{\displaystyle \{y_{t}\}}

 называется стационарным в широком смысле, если:

E
(

y

t

)
=
μ

{\displaystyle E(y_{t})=\mu }

V
a
r
(

y

t

)
=

σ

2

{\displaystyle Var(y_{t})=\sigma ^{2}}

C
o
v
(

y

t

,

y

t
−
k

)
=
C
o
v
(

y

t
+
s

,

y

t
−
k
+
s

)
=
γ
(
k
)

{\displaystyle Cov(y_{t},y_{t-k})=Cov(y_{t+s},y_{t-k+s})=\gamma (k)}

Стационарный временной ряд – это такой ряд, который не меняется со временем с каким-либо трендом, то есть не растет и не снижается. Фор-мально это означает, что математическое ожидание стационарного времен-ного ряда – постоянно, равно как и его дисперсия, а его значения на равном расстоянии друг от друга связаны одинаково.

12.2 Процессы AR, MA, ARMA и ARIMA

Определение 12.0 Белый шум *y*_{*t*} ~ *WN*(0, *σ*²) – слабо стационарный процесс, обладающий следующими свойствами:

E
(

y

t

)
=
E
(

y

s

)
=
0

{\displaystyle E(y_{t})=E(y_{s})=0}

V
a
r
(

y

t

)
=
V
a
r
(

y

s

)
=

σ

2

{\displaystyle Var(y_{t})=Var(y_{s})=\sigma ^{2}}

C
o
v
(

y

t

,

y

s

)
=
0

{\displaystyle Cov(y_{t},y_{s})=0}

Определение 12.1 *AR*(*p*) – процесс, зависящий только от своих предыдущих значений и ошибки в текущий момент времени:

y

t

=
c
+

α

1

y

t
−
1

+

α

2

y

t
−
2

+
.
.
.
+

α

p

y

t
−
p

+

ε

t

=
c
+

∑

i
=
1

p

α

i

y

t
−
i

+

ε

t

{\displaystyle \;\;\;\;\;y_{t}=c+\alpha _{1}y_{t-1}+\alpha _{2}y_{t-2}+...+\alpha _{p}y_{t-p}+\varepsilon _{t}=c+\sum _{i=1}^{p}\alpha _{i}y_{t-i}+\varepsilon _{t}}

t
=
1
,
.
.
.
,
T
;

ε

t

∼
W
N
(
0
,

σ

2

)

{\displaystyle t=1,...,T;\;\;\;\varepsilon _{t}\sim WN(0,\sigma ^{2})}

Определение 12.2 *MA*(*q*) – процесс, зависящий только от лагов слу-чайной ошибки:

y

t

=
c
+

ε

t

+

β

1

ε

t
−
1

+
.
.
.
+

β

q

ε

t
−
q

=
c
+

∑

i
=
1

q

β

i

ε

t
−
i

+

ε

t

{\displaystyle \;\;\;\;\;y_{t}=c+\varepsilon _{t}+\beta _{1}\varepsilon _{t-1}+...+\beta _{q}\varepsilon _{t-q}=c+\sum _{i=1}^{q}\beta _{i}\varepsilon _{t-i}+\varepsilon _{t}}

t
=
1
,
.
.
.
,
T
;

ε

t

∼
W
N
(
0
,

σ

2

)

{\displaystyle t=1,...,T;\;\;\;\varepsilon _{t}\sim WN(0,\sigma ^{2})}

Определение 12.3 *ARMA*(*p*, *q*) – процесс, зависящий и от своих предыдущих значений, и от текущей и предыдущих ошибок:

y

t

=
c
+

∑

i
=
1

p

α

i

y

t
−
i

+

∑

j
=
1

q

β

j

ε

t
−
j

+

ε

t

{\displaystyle \;\;\;\;\;y_{t}=c+\sum _{i=1}^{p}\alpha _{i}y_{t-i}+\sum _{j=1}^{q}\beta _{j}\varepsilon _{t-j}+\varepsilon _{t}}

t
=
1
,
.
.
.
,
T
;

ε

t

∼
W
N
(
0
,

σ

2

)

{\displaystyle t=1,...,T;\;\;\;\varepsilon _{t}\sim WN(0,\sigma ^{2})}

Как выбрать оптимальное число лагов? Можно использовать информа-ционные критерии Акаике (AIC) и Шварца (BIC):

A
I
C
(
p
,
q
)
=
ln
⁡
σ

2

+
2

p
+
q
+
1

T

→
min

p
,
q

{\displaystyle AIC(p,q)=\ln {\hat {\sigma }}^{2}+2{\frac {p+q+1}{T}}\longrightarrow \min _{p,q}}

B
I
C
(
p
,
q
)
=
ln
⁡
σ

2

+

p
+
q
+
1

T

ln
⁡
T
→
min

p
,
q

{\displaystyle BIC(p,q)=\ln {\hat {\sigma }}^{2}+{\frac {p+q+1}{T}}\ln T\longrightarrow \min _{p,q}}

Также можно провести тесты Льюнг - Бокса и Бокса - Пирса.

Оба проверяют следующую гипотезу:

*H*₀ : процесс - *WN*(0, *σ*²)

*H*_{*a*} : процесс - *ARMA*(*p*, *q*)

1. Q-тест Льюнг - Бокса. Статистика рассчитывается как:

Q

k

=
T
(
T
+
2
)

∑

k
=
1

K

1

T
−
K

r

k

2

∼

χ

2

K
−
p
−
q
−
1

{\displaystyle Q_{k}=T(T+2)\sum _{k=1}^{K}{\frac {1}{T-K}}r_{k}^{2}\sim \chi _{K-p-q-1}^{2}}

2. Q-статистика Бокса - Пирса. Статистика рассчитывается как:

Q

k

=
T

∑

k
=
1

K

r

k

2

∼

χ

2

K
−
p
−
q
−
1

{\displaystyle Q_{k}=T\sum _{k=1}^{K}r_{k}^{2}\sim \chi _{K-p-q-1}^{2}}

В обоих случаях, если при выбранном уровне значимости величина стати-стики превышает критическое значение, основная гипотеза отвергается.

Определение 12.4 Если для некоторого ряда *y*_{*t*} необходимо взять *d* разностей, чтобы привести его к стационарному виду, а ряд *Δy*_{*t*} описывается моделью *ARMA*(*p*, *q*), то ряд *y*_{*t*} описывается моделью *ARIMA*(*p*, *d*, *q*).

12.3 Тест Дики - Фуллера на стационарность ряда

Для начала необходимо привести исходный ряд к виду *Δy*_{*t*} = *δ* + *γt* + (*θ* – 1)*y*_{*t*–1} + *ε*_{*t*}, где *δ* – константа, а *γt* отвечает за тренд. Гипотеза формулируется как:

*H*₀ : *θ* – 1 = 0 - ряд нестационарный

*H*_{*a*} : *θ* – 1 < 0 - ряд стационарный

При этом предполагается, что *ε*_{*i*} ~ *N*(0, *σ*²).

Тестовая статистика (DF-статистика) рассчитывается по формуле, анало-гичной с формулой t-статистики на значимость коэффициента:

D
F
=

θ
^
−
1

√
V
a
r
^
(
θ
^
−
1
)

{\displaystyle DF={\frac {\hat {\theta }-1}{\sqrt {\hat {Var}(\hat {\theta }-1)}}}

У статистики Дики-Фуллера своя таблица критических значений и свое распределение, если тестовая статистика находится правее критического значения, то нулевая гипотеза отвергается. При этом критическое значе-ние рассчитывается исходя из спецификации теста:

- Без константы;
- С константой;
- С константой и трендом.

12.4 Ложная корреляция и коинтеграция

Ложная корреляция – эффект, при котором между двумя перемен-ными наблюдается значимая корреляция, при этом отсутствует каче-ственная причинно-следственная связь. Может возникать из-за того, что обе переменные являются нестационарными, и в них обеих наблю-дается стохастический тренд.

Коинтеграция – свойство нескольких нестационарных временных ря-дов, заключающееся в существовании некоторой их стационарной ли-нейной комбинации.

Говорят, что нестационарный ряд является интегрированным порядка *d*, если необходимо взять *d* разностей, чтобы его к стационарному виду. Такие ряды означаются как *I*(*d*).

Рассмотрим два нестационарных ряда: *y*_{*t*} ~ *I*(*d*) и *x*_{*t*} ~ *I*(*d*),где *I*(*d*). Если существует такой вектор (α,β) : α ≠ 0, β ≠ 0, что α*y*_{*t*} + β*x*_{*t*} ~ *I*(*d* – *b*), *b* > 0, то ряды называются *коинтегрированными* порядка *b*.