

Эконометрика, НИУ ВШЭ

Составили эконометрессы Максимовская Анастасия, Перевышина Татьяна, Ситникова Арина, а также Пилипейко Роман

1.0 Линейная регрессия с одной объясняющей переменной (парная регрессия)


Линейная регрессионная модель имеет следующий вид:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

1.1 Метод наименьших квадратов (OLS) для нахождения оценок коэффициентов парной регрессии

Зачем он нужен? Для нахождения оценок коэффициентов $\hat{\beta}_1, \hat{\beta}_2$

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$$
$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$
$$\hat{\beta}_2 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{s\text{Cov}(x, y)}{s\text{Var}(x)}$$



$$s\text{Cov}(x; y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Проекция y на $Lin(1; x)$: $\hat{y} = \hat{\beta}_1 \mathbb{1} + \hat{\beta}_2 x^c$

Проекция x и y на $Lin\perp(\mathbb{1})$: $x^c = x - \bar{x}\mathbb{1} = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}, y^c = y - \bar{y}\mathbb{1} = \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}$

Проекция x и y на $Lin\perp(\mathbb{1})$: $x^c = x - \bar{x}\mathbb{1} = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}$

Проекция y^c на $Lin(x^c)$: $\beta_2 x^c = \hat{y} - \bar{y}\mathbb{1}$

Проекция x^c на $Lin(\mathbb{1})$: 0

Проекция x^c на $Lin\perp(\mathbb{1})$: x^c

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2 = ESS + RSS = |y - \bar{y}\mathbb{1}|^2 = AB^2 = y^c{}^2$$
$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = AC^2$$
$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2 = BC^2$$
$$R^2 = \frac{ESS}{TSS} = \frac{s\text{Var}(\hat{y})}{s\text{Var}(y)} = \frac{AC^2}{AB^2} = \cos(\varphi') = s\text{Corr}^2(y; \hat{y}) = s\text{Corr}^2(y; x)$$

1.2 Теорема Гаусса - Маркова для случая парной регрессии

Зачем она нужна? Для получения дополнительной информации о характеристиках распределения оценок $\hat{\beta}_1, \hat{\beta}_2$

Теорема 1.2 Гаусса - Маркова для случая парной регрессии

Если для модели $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i + \varepsilon_i, i = 1, \dots, n$ выполняются следующие условия:

- 1) Строится регрессия y на x
- 2) Не все x_i равны между собой
- 3) Математическое ожидание от любой ошибки регрессии равно 0
- 4) Дисперсия от любой ошибки регрессии равна σ_ε^2
- 5) $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ - отсутствие автокорреляции,

то МНК - оценки $\hat{\beta}_1$ и $\hat{\beta}_2$ являются *BLUE*

Best (наилучшие)	для любых $\hat{\beta}_i$ верно: $MSE(\hat{\beta}_i) \leq MSE(\beta_i)$
Linear (линейные)	Оценки линейные по y
Unbiased (несмещенные) Estimator (оценки)	$E(\hat{\beta}_i) = \beta_i$

Утверждение 1.2 Если условия теоремы Гаусса - Маркова выполнены, то дисперсии МНК оценок:

$$\text{Var}(\hat{\beta}_1) = \sigma_\varepsilon^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \quad \text{Var}(\hat{\beta}_2) = \frac{\sigma_\varepsilon^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

а их ковариация:

$$\text{Cov}(\hat{\beta}_1, \hat{\beta}_2) = -\frac{\bar{x} \sigma_\varepsilon^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

1.3 Предположение о нормальном распределении случайной ошибки в рамках классической линейной регрессии

Утверждение 1.3.1 Если верно, что $\varepsilon_i \sim N(0, \sigma_\varepsilon^2), i = 1 \dots n$, то МНК-оценки коэффициентов парной регрессии также имеют нормальное распределение, причём $\hat{\beta}_1 \sim N(\beta_1, \text{Var}(\hat{\beta}_1)), \hat{\beta}_2 \sim N(\beta_2, \text{Var}(\hat{\beta}_2))$.

Утверждение 1.3.2 $\hat{\sigma}_\varepsilon^2 = \frac{RSS}{n-2}$ является несмещённой оценкой для σ_ε^2 .

Утверждение 1.3.3 $\frac{RSS}{\hat{\sigma}_\varepsilon^2} \sim \chi_{n-2}^2$ для парной регрессии.

Утверждение 1.3.4 Оценки $\hat{\beta}_1$ и $\hat{\sigma}_\varepsilon^2, \hat{\beta}_2$ и $\hat{\sigma}_\varepsilon^2$ являются независимыми.

1.3.1 Проверка гипотезы о конкретном значении коэффициентов парной регрессии

$$H_0 : \beta_2 = \beta_2^0$$
$$H_a : \beta_2 \neq \beta_2^0$$

Если $|t| = \frac{\hat{\beta}_2 - \beta_2^0}{\sqrt{\hat{\text{Var}}(\hat{\beta}_2)}} > t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 отвергается в пользу гипотезы H_a .
Если значение $|t| = \frac{\hat{\beta}_2 - \beta_2^0}{\sqrt{\hat{\text{Var}}(\hat{\beta}_2)}} < t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 не отвергается.

1.3.2 Проверка гипотезы о значимости коэффициентов парной регрессии

$$H_0 : \beta_2 = 0$$
$$H_a : \beta_2 \neq 0$$

Если значение $|t| = \frac{\hat{\beta}_2}{\sqrt{\hat{\text{Var}}(\hat{\beta}_2)}} > t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 отвергается, значит, β_2 значим.

Если значение $|t| = \frac{\hat{\beta}_i}{\sqrt{\hat{\text{Var}}(\hat{\beta}_2)}} < t^{cr}$ (при уровне значимости $\alpha/2$ и $n - 2$ степенях свободы), то гипотеза H_0 не отвергается, значит, β_2 не значим.

Доверительный интервал

$$[\hat{\beta}_2 - t^{cr} \sqrt{\hat{\text{Var}}(\hat{\beta}_2)}; \hat{\beta}_2 + t^{cr} \sqrt{\hat{\text{Var}}(\hat{\beta}_2)}]$$

Если доверительный интервал включает в себя нуль, то этот коэффициент не значим, при уровне значимости α .
В обоих случаях t^{cr} рассчитывается на уровне значимости $\alpha/2$ с $n - 2$ степенями свободы.

1.3.3 Прогнозирование по модели парной регрессии и его точность

Доверительный интервал для среднего прогноза

$$\hat{\text{Var}}(\hat{y}_{n+1}) = \hat{\text{Var}}(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1}) = \hat{\sigma}_\varepsilon^2 [1 + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}]$$
$$P(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} - t_{\alpha/2, n-2} \sqrt{\hat{\text{Var}}(\hat{y}_{n+1})} \leq E(y_{n+1} | x = x_{n+1}) \leq \hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + t_{\alpha/2, n-2} \sqrt{\hat{\text{Var}}(\hat{y}_{n+1})}) = 1 - \alpha$$

Доверительный интервал для индивидуального прогноза

$$\hat{\text{Var}}(y_{n+1}) = \hat{\text{Var}}(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + \varepsilon_{n+1}) = \hat{\sigma}_\varepsilon^2 [1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}]$$
$$P(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} - t_{\alpha/2, n-2} \sqrt{\hat{\text{Var}}(y_{n+1})} \leq y_{n+1} \leq \hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + t_{\alpha/2, n-2} \sqrt{\hat{\text{Var}}(y_{n+1})}) = 1 - \alpha$$

Доверительный интервал дисперсии ошибок регрессии

$$P(\frac{RSS}{\chi_{\alpha/2, n-2}^2} \leq \sigma_\varepsilon^2 \leq \frac{RSS}{\chi_{1-\alpha/2, n-2}^2}) = 1 - \alpha$$

1.3.4 Проверка гипотезы о нормальности распределения

Критерий Колмогорова - Смирнова

Когда используется? Выборка состоит из достаточно большого количества наблюдений n

$$H_0 : F(t) = G(t) \text{ для любого } t$$
$$H_a : F(t) \neq G(t) \text{ при некотором } t$$

С использованием таблиц:


$$J = \frac{mn}{d} \max_{-\infty < t < \infty} |F_m(t) - G_n(t)|$$

где $F_m(t)$ и $G_m(t)$ — эмпирические функции распределения для выборок x_1, \dots, x_m и y_1, \dots, y_n , а именно:

$$F_m(t) = \frac{\text{Число элементов в первой выборке, не превышающих } t}{m}$$
$$G_n(t) = \frac{\text{Число элементов во второй выборке, не превышающих } t}{n}$$

d — НОД(m, n), m и n — общее количество элементов в первой и второй выборке соответственно.

Статистика имеет специальное распределение D при верной H_0 :



Тест Харке - Бера Когда используется? Выборка состоит из достаточно большого количества наблюдений n

$$H_0 : s = 0, k = 3$$
$$H_a : s \neq 0, k \neq 3$$

Тестовая статистика:

$$JB = \frac{n}{6} (s^2 + \frac{1}{4} (k - 3)^2) \sim \chi_2^2$$

Коэффициент асимметрии: $s = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^3}{\bar{\sigma}^3}, \bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

Для симметричных распределений, в том числе нормального, этот показатель равен нулю.

Коэффициент эксцесса: $k = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^4}{\bar{\sigma}^4}$
Для нормального распределения этот показатель равен 3.

Если $JB > \chi_2^2$ при выбранном уровне значимости, то гипотеза отвергается.

Тест Шапиро - Уилка

Когда используется? Выборка состоит из небольшого количества наблюдений n

$$H_0 : x_1, \dots, x_n \text{ - выборка из нормального распределения}$$
$$H_a : x_1, \dots, x_n \text{ - выборка не из нормального распределения}$$

Тестовая статистика:

$$W = \frac{(\sum_{i=1}^n \alpha_{(i)} x_i)^2}{\sum_{i=1}^n (x_{(i)} - \bar{x})^2} \sim W_\alpha$$

Вектор коэффициентов: $\alpha_{(i)} = \frac{m^T V^{-1}}{m^T V^{-1} V^{-1} m}$
 m — вектор математических ожиданий порядковых статистик нормального распределения;
 V — ковариационная матрица этих порядковых статистик размера $n \times n$.

Для небольших n коэффициенты $\alpha_{(i)}$ берутся из таблиц.

Если $W < W_\alpha$, то гипотеза H_0 отвергается.

$$H_a : \beta_j \neq 0$$

При *θ
̂

as

N
(
θ
;

I

−
1

(
θ
)

)* тестовая статистика рассчитывается как:

$$z = \frac{\hat{\beta}_j}{\sqrt{\hat{\text{Var}}(\hat{\beta}_j)}}$$

Если

|
z
|
≥

z

α

/
2

, где *α* - выбранный уровень значимости, то гипотеза *H*0 о незначимости отвергается. Однако интерпретировать можно только знак оценки коэффициента (если

β
̂

j

>
0, то при увеличении *x*  *j* вероятность того, что *y*  *i* = 1 увеличивается, и наоборот), а не его абсолютное значение.

9.4 Предельные эффекты

Функция *F*(*x*) является нелинейной, поэтому для интерпретации влияния каждого фактора рассчитываются предельные эффекты (частные производные):

$$\frac{\partial \hat{p}_i}{\partial x_j}(x_1,\ldots,x_k)=f(x_1,\ldots,x_k)\hat{\beta}_j,\quad i=1,\ldots,n,j=1,\ldots,k$$

Чаще всего в качестве точки, в которой рассчитывается предельный эффект, выбирается

x
¯

1
,
.
.
.
,

x
¯

k

.

Для фиктивных переменных предельные эффекты рассчитываются по формуле:

$$\frac{\partial \hat{p}_i}{\partial x_j}(x_1,\ldots,x_k)=\hat{p}(x_1,\ldots,x_{j-1},D=1,x_{j+1},\ldots,x_k)\hskip-1pt$$

$$\hskip-1pt-\hat{p}(x_1,\ldots,x_{j-1},D=0,x_{j+1},\ldots,x_k)$$

9.5 Показатели качества оценки моделей бинарного выбора

Нижe приведены несколько популярных метрик для оценки моделей бинарного выбора.

- R*² МакФаддена:

$$R_{MF}^2=1-\frac{\hat{l}_{ML}}{l_0},$$

где **l** — значение логарифмической функции правдоподобия в точке максимума, а *l*  *0* — максимум логарифмической функции правдоподобия для модели, в которую включена только константа.

- Псевдо-*R*²:

$$R_p^2=\frac{1}{1+\frac{2}{n}(\hat{l}_{ML}-l_0)}$$

Альтернативным критерием оценки качества модели является *сравнение точности прогнозирования* по оцененной модели бинарного выбора. Прогноз строится следующим образом:

$$\hat{y}_i=\begin{cases}1, \text{ если } F(\hat{\beta}_1+\hat{\beta}_2x_{i2}+\ldots+\hat{\beta}_kx_{ik})>0.5\\0, \text{ если } F(\hat{\beta}_1+\hat{\beta}_2x_{i2}+\ldots+\hat{\beta}_kx_{ik})\leq0.5\end{cases}$$

Доля неверных прогнозов вычисляется по формуле:

$$W_1=\frac{1}{n}\sum_{i=1}^n(y_i-\hat{y}_i)^2.$$

Данная доля интересна в сравнении с долей неверных прогнозов в самой простой бинарной модели, в которую включена только константа. Прогнозы для простой модели строятся так:

y
̂

i

=
1, если в выборке доля единиц превышает 0.5. Если больше нулей, то

y
̂

i

=
0. Доля неверных прогнозов для простой модели:

$$W_0=\begin{cases}1-\hat{p}, \text{ если } \hat{p}>0.5\\\hat{p}, \text{ если } \hat{p}\leq0.5\end{cases}$$

Показатель качества подгонки модели:

$$R_{fit}^2=1-\frac{W_1}{W_0}$$

10.0 Эндогенность

Эндогенность — это коррелированность регрессоров и случайных ошибок:
 Cov (X , ε<!-- ε -->) ≠<!-- ≠ --> 0 {\displaystyle \mathrm {Cov} (X,\varepsilon)\neq 0}

Утверждение 10.1 Если регрессоры не коррелирует с ошибкой <i>ε</i> , т.е. plim n →<!-- → --> ∞<!-- ∞ --> (1 n X T ε<!-- ε -->) = 0 , то ТГМ не нарушается:
 plim n →<!-- → --> ∞<!-- ∞ --> β<!-- β --> ^<!-- ^ --> = β<!-- β --> + plim n →<!-- → --> ∞<!-- ∞ --> (1 n X T X) −<!-- − --> 1 plim n →<!-- → --> ∞<!-- ∞ --> (1 n X T ε<!-- ε -->) = β<!-- β --> {\displaystyle \mathrm {plim} _{n\rightarrow \infty }\beta ^{\wedge }=\beta +\mathrm {plim} _{n\rightarrow \infty }({\frac {1}{n}}X^{T}X)^{-1}\mathrm {plim} _{n\rightarrow \infty }({\frac {1}{n}}X^{T}\varepsilon)=\beta }
При этом существование предела plim n →<!-- → --> ∞<!-- ∞ --> (1 n X T X) −<!-- − --> 1 является дополнительным требованием.

Утверждение 10.2 Если существует такой регрессор <i>x</i>  <i>j</i> , что plim n →<!-- → --> ∞<!-- ∞ --> (1 n x j T ε<!-- ε -->) ≠<!-- ≠ --> 0 , то имеет место проблема эндогенности, и оценки МНК не будут состоятельны.

10.1 Причины возникновения эндогенности

- Пропуск существенной переменной;
- Ошибки измерения;
- Одновременность изменения зависимой и эндогенной объясняющей переменной;
- Проблема самоотбора;

10.2 Способы борьбы с эндогенностью

10.2.1 Инструментальные переменные

Утверждение 10.3 Переменная <i>z</i>  <i>i</i> является инструментальной для проблемного регрессора <i>x</i>  <i>i</i> если:
 Cov (x i , z i) > 0 — свойство релевантности {\displaystyle \mathrm {Cov} (x_{i},z_{i})>0\,\!{\text{— свойство релевантности}}}
 Cov (z i , ε<!-- ε --> i) = 0 — свойство валидности {\displaystyle \mathrm {Cov} (z_{i},\varepsilon _{i})=0\,\!{\text{— свойство валидности}}}
При этом второе условие можно заменить более слабым:
 plim n →<!-- → --> ∞<!-- ∞ --> (1 n z i T ε<!-- ε -->) = 0 {\displaystyle \mathrm {plim} _{n\rightarrow \infty }({\frac {1}{n}}z_{i}^{T}\varepsilon)=0}

Метод инструментальных переменных (IV)

Когда используется? При возникновении проблемы эндогенности.

- Для модели парной регрессии *y*  *i* = β₁ + β₂*x*  *i* + ε_{*i*} с эндогенной переменной *x* и инструментом *z*:
- $$\hat{\beta}^{IV}_2=\frac{\text{sCov}(z,y)}{\text{sCov}(z,x)}$$
- Для модели множественной регрессии *y*  *i* = β₁ + β₂*x*  *i2* + . . . + β_{*k*}*x*  *i*  *k* + ε_{*i* с рядом эндогенных переменных и инструментами *z*  1, . . . , *z*  *m*:}

Случай 1: m=k (количество инструментов совпадает с количеством переменных в исходной модели)

$$\hat{\beta}^{IV}=(Z^TX)^{-1}Z^Ty$$

Эта оценка несмещенная и состоятельная, а также отвечает свойствам релевантности и валидности.

<i>Случай 2: m>k</i> (количество инструментов превышает количество переменных в исходной модели)

В этом случае необходимо применить двухшаговый МНК (2SLS):

Шаг 1. Построить регрессию всех регрессоров, коррелированных с ошибками, на инструментальные переменные:

$$X=Z\gamma +\varepsilon$$

Получить

X
^

=
Z
(

Z

T

Z
)

−
1

Z

T

X
.

{\displaystyle {\hat {X}}=Z(Z^{T}Z)^{-1}Z^{T}X.}

Шаг 2. Оценить исходную модель, подставив полученный

X
^
:

$$y=\hat{X}\beta +\varepsilon$$

Тогда при

X
^

=
Z
(

Z

T

Z
)

−
1

Z

T

X

 оценка методом инструментальных переменных будет следующая:

$$\hat{\beta}^{2SLS}=(\hat{X}^T\hat{X})^{-1}\hat{X}^Ty=(X^TZ(Z^TZ)^{-1}Z^TX)^{-1}X^TZ(Z^TZ)^{-1}Z^Ty$$

10.2.2 Обобщенный метод моментов (GMM)

Если имеется m инструментов <i>z</i>  1, . . . , <i>z</i>  <i>m</i>, то можно определить функцию <i>g</i>  <i>i</i>(β) = z_{  <i>i</i>}(<i>y</i>  <i>i</i> − <i>x</i>  <i>i</i>  <i>i</i>  <i>i</i>  <i>i</i>  <i>i</i>β) , которая называется моментом.

Если инструменты экзогенны, должно быть выполнено моментное тождество <i>E(g_{  <i>i</i>(β))}</i> = 0
--

Выборочный аналог моментного тождества будет иметь вид:
 g ¯<!-- ¯ --> (β<!-- β -->) = 1 n ∑<!-- ∑ --> i = 1 n z i (y i −<!-- − --> x i T β<!-- β -->) {\displaystyle {\bar {g}}(\beta)={\frac {1}{n}}\sum _{i=1}^{n}z_{i}(y_{i}-x_{i}^{T}\beta)}

Применение GMM для получения оценок линейной регрессионной модели.

$$y_i=\beta _1+\beta _2x_{i2}+\ldots +\beta _kx_{ik}+\varepsilon _i$$

$$(z_1\ldots z_m)\hbox{— инструменты}$$

Случай 1: m=k (Число моментных тождеств, которое соответствует числу инструментов, совпадает с количеством регрессоров)
Оценка вектора коэффициентов

β
^
 будет решением уравнения

g
¯

(
β
)
=
0
:

{\displaystyle {\bar {g}}(\beta)=0:}

$$\hat{\beta}^{IV}=\hat{\beta}^{GMM}$$

Случай 2: m>k

$$Q(\beta)=(\frac{1}{n}Z^T(y-X\beta))^TW(\frac{1}{n}Z^T(y-X\beta))\rightarrow \min _{\beta }$$

$$\hat{\beta}^{GMM}=(X^TZWZ^TX)^{-1}X^TZWZ^Ty$$

где *W* – некая весовая матрица. Наиболее эффективными являются GMM-оценки с весовой матрицей, равной обратной ковариационной матрице моментных функций.

10.3 Проверка качества инструментов

При использовании инструментальных переменных необходимо убедиться в том, что они удовлетворяют двум основным условиям:

1) Условие релевантности (*z* коррелирует с *x*)
Это условие проверяется следующим образом:
Шаг 1. Оценивается регрессия

$$x_i^{*}=z_i^T\beta +\varepsilon$$

где *x*  *i*^{*} - вектор эндогенных переменных.
Шаг 2. Рассчитывается статистика F для проверки гипотезы об адекватности регрессии. Если её значение выше 10, то инструменты приемлемы.

2) Условие валидности (*z* не коррелирует с ошибками)
При **m=k** проверить валидность невозможно.
Однако при **m>k** возможны два варианта:

Случай 1: При гомоскедастичности.

При гомоскедастичности используется **Тест Саргана**:

$$H_0\,:\,\text{инструменты валидны}$$

$$H_a\,:\,\text{инструменты не валидны}$$

В тесте используется статистика вида:

$$\zeta (\hat{\beta}^{GMM})=\frac{1}{\hat{\sigma}_{\hat{\varepsilon}}^2}\hat{\varepsilon}^TZ(Z^TZ)^{-1}Z^T\hat{\varepsilon}\sim \chi _{m-k}^2$$

Если рассчитанное значение превышает критическое при выбранном уровне значимости, то гипотеза *H*0 отвергается, инструменты слабые.

Случай 2: При гетероскедастичности.
При гетероскедастичности используется **Тест Хансена**:

$$H_0\,:\,\text{инструменты валидны}$$

$$H_a\,:\,\text{инструменты не валидны}$$

В тесте используется статистика вида:

$$\zeta (\hat{\beta}^{GMM})=\hat{\varepsilon}^TZ(Z^T\hat{\Omega}Z)^{-1}Z^T\hat{\varepsilon}\sim \chi _{m-k}^2$$

Если рассчитанное значение превышает критическое при выбранном уровне значимости, то гипотеза *H*0 отвергается, инструменты слабые.

10.4 Тест Хаусмана

Для чего используется? Чтобы определить, имеет ли место проблема эндогенности в модели

$$H_0\,:\,\text{нет эндогенности; }\hat{\beta}^{OLS}\text{ и }\hat{\beta}^{IV}\text{— состоятельные}$$

$$H_a\,:\,\text{есть эндогенность; }\hat{\beta}^{IV}\text{— состоятельна, }\hat{\beta}^{OLS}\text{— несостоятельна}$$

Пусть

q
^

=

β
^

IV

−

β
^

OLS

. Тогда в тесте используется статистика вида:

$$\chi ^2=\hat{q}^T(\hat{\text{Var}}(\hat{\beta}^{IV})-\hat{\text{Var}}(\hat{\beta}^{OLS}))^{-1}\hat{q}\sim \chi _{k+1}^2$$

Если рассчитанное значение статистики превышает критическое при выбранном уровне значимости, то гипотеза *H*0 отвергается, и нужно использовать инструментальные переменные.

Также можно провести процедуру **Дарбина-Ву-Хаусмана**:
Пусть *y*  *i* = β₁ + β₂*x*  *i* + ε_{*i*} ; *z*  *i* - инструмент.

$$H_0\,:\,\text{нет эндогенности}$$

$$H_a\,:\,\text{есть эндогенность}$$

Проверка гипотезы осуществляется следующим образом:
Шаг 1. Строим вспомогательную регрессию *x*  *i* = α₁ + α₂*z*  *i* + ν_{*i*}, получаем

ν
̂

i

.
Шаг 2. Строим регрессию *y*  *i* = β₁ + β₂*x*  *i* + δν_{*i*} + ε<sub>*i*.
Если коэффициент *δ* значим, то гипотеза *H*0 отвергается.</sub>

11.0 Автокорреляция

Автокорреляция — это нарушение условия теоремы Гаусса-Маркова о некоррелируемости ошибок регрессии:
 Cov (ε<!-- ε --> i , ε<!-- ε --> j) ≠<!-- ≠ --> 0 {\displaystyle \mathrm {Cov} (\varepsilon _{i},\varepsilon _{j})\neq 0}

Автокорреляция 1-го порядка: *ε*  *t* = ρε_{*t*−1} + *u*  *t*, где *u*  *t* ∼ i.i.d.(0,σ_{*u*}²)
При этом переменная *ρ* — коэффициент автокорреляции,

|
ρ
|
<
1

{\displaystyle |\rho |<1}

. Ошибка текущего момента может зависеть не только от ошибки предыдущего периода, но и от ошибок предшествовавших периодов, поэтому могут существовать автокорреляции более высоких порядков:

$$\varepsilon _{t}=\rho _{1}\varepsilon _{t-1}+\rho _{2}\varepsilon _{t-2}+\ldots +\rho _{p}\varepsilon _{t-p}+u_{t}$$

Утверждение 11.1 Если Cov (u i , u j) = 0 , i ≠<!-- ≠ --> j , {\displaystyle \mathrm {Cov} (u_{i},u_{j})=0,\,i\neq j,} то:
 σ<!-- σ --> ε<!-- ε --> 2 = Var (ε<!-- ε --> t) = σ<!-- σ --> u 2 (1 + ρ<!-- ρ --> 2 + ρ<!-- ρ --> 4 + . . .) = σ<!-- σ --> u 2 1 −<!-- − --> ρ<!-- ρ --> 2 , ρ<!-- ρ --> < 1 {\displaystyle \sigma _{\varepsilon }^{2}=\mathrm {Var} (\varepsilon _{t})=\sigma _{u}^{2}(1+\rho ^{2}+\rho ^{4}+\ldots)={\frac {\sigma _{u}^{2}}{1-\rho ^{2}}},\, \rho <1}
 Cov (ε<!-- ε --> t , ε<!-- ε --> t −<!-- − --> 1) = ρ<!-- ρ --> σ<!-- σ --> u 2 (1 + ρ<!-- ρ --> 2 + ρ<!-- ρ --> 4 + . . .) = ρ<!-- ρ --> σ<!-- σ --> u 2 1 −<!-- − --> ρ<!-- ρ --> 2 = ρ<!-- ρ --> σ<!-- σ --> ε<!-- ε --> 2 {\displaystyle \mathrm {Cov} (\varepsilon _{t},\varepsilon _{t-1})=\rho \sigma _{u}^{2}(1+\rho ^{2}+\rho ^{4}+\ldots)=\rho {\frac {\sigma _{u}^{2}}{1-\rho ^{2}}}=\rho \sigma _{\varepsilon }^{2}}
 Cov (ε<!-- ε --> t , ε<!-- ε --> t −<!-- − --> s) = ρ<!-- ρ --> s σ<!-- σ --> ε<!-- ε --> 2 {\displaystyle \mathrm {Cov} (\varepsilon _{t},\varepsilon _{t-s})=\rho ^{s}\sigma _{\varepsilon }^{2}}


При автокорреляции оценки МНК будут несмещенными, но неэффективными. Стандартные ошибки коэффициентов будут недооценены, t-статистики будут слишком большие.

11.1 Причины возникновения автокорреляции

- Пропуск существенной переменной;
- Инертность макроэкономических данных;
- Сглаживание первоначальных данных;
- Неправильная форма модели;

11.2 Способы обнаружения автокорреляции

Первый способ: Графический.



На картинке (а) изображен график нормальных остатков по времени. На всех остальных изображены графики остатков с различными видами автокорреляции.

Второй способ: Проведение тестов на выявление автокорреляции.

- Тест серий**.

Для проведения теста выписываются знаки остатков по очереди, при этом *серия* — набор остатков одного знака.
Дано: *T* — общее число наблюдений, *N*₁ — число положительных остатков, *N*₂ — число отрицательных остатков, *K* — число серий.

*H*₀ : нет автокорреляции

*H*_{*a*} : положительная автокорреляция/отрицательная автокорреляция

Если *K* ≤ *K*_{*min*} — автокорреляция положительная;

Если *K* ≥ *K*_{*max*} — автокорреляция отрицательная.

При этом *K*_{*min*} = min{*N*₁; *N*₂} − 1, *K*_{*max*} = max{*N*₁, *N*₂} + 1.

Если *T* > 40, справедливо следующее:

K

as

N

(

2

N

1

N

2

N

1

+

N

2

+
1
;

2

N

1

N

2

(
2

N

1

N

2

−

N

1

−

N

2

)

(

N

1

+

N

2

)

2

(

N

1

+

N

2

−
1
)

)

{\displaystyle K^{as}N\left({\frac {2N_{1}N_{2}}{N_{1}+N_{2}}}+1;{\frac {2N_{1}N_{2}(2N_{1}N_{2}-N_{1}-N_{2})}{(N_{1}+N_{2})^{2}(N_{1}+N_{2}-1)}}\right)}

- Тест Дарбина - Уотсона**.

В этом тесте используется особая статистика, которая так и называется — статистика Дарбина - Уотсона (DW-статистика). Рассчитывается она следующим образом:

D
W
=

∑

t
=
2

T

(

e

t

−

e

t
−
1

)

2

∑

t
=
1

T

e

t

2

≈
2
−
2
ρ
,
|
ρ
|
<
1
⇒
0
<
2
−
2
ρ
<
4

{\displaystyle DW={\frac {\sum _{t=2}^{T}(e_{t}-e_{t-1})^{2}}{\sum _{t=1}^{T}e_{t}^{2}}}\approx 2-2\rho ,\,|\rho |<1\Rightarrow 0<2-2\rho <4}

Тестирование на автокорреляцию с помощью DW-статистики проводит-ся по следующей гипотезе:

*H*₀ : *ρ* = 0, т.е. отсутствие автокорреляции

*H*_{*a*} : *ρ* > 0 ЛИБО *ρ* < 0

Для проведения расчетов используются две вспомогательные пере-менные *d*_{*u*} и *d*_{*L*}, значения которых заданы таблично. При этом: 0 < *d*_{*L*} < *d*_{*u*} < 2.

При *H*_{*a*} : *ρ* > 0 (положительная автокорреляция):

1)*DW* < *d*_{*L*} ⇒ Присутствует положительная автокорреляция.

2)*d*_{*L*} ≤ *DW* ≤ *d*_{*U*} ⇒ Определить наличие автокорреляции невозмож-но.

3)*DW* > *d*_{*U*} ⇒ Положительная автокорреляция отсутствует.

При *H*_{*a*} : *ρ* < 0 (отрицательная автокорреляция):

1)*DW* > (4 − *d*_{*L*}) ⇒ Присутствует отрицательная автокорреляция.

2)(4 − *d*_{*U*}) ≤ *DW* ≤ (4 − *d*_{*L*}) ⇒ Определить наличие автокорреляции невозможно.

3)*DW* < (4 − *d*_{*U*}) ⇒ Отрицательная автокорреляция отсутствует.

- Тест Бройша - Годфри**.

В отличие от предыдущих тестов, этот тест используется для выяв-ления автокорреляции более 1-го порядка.

Пусть *y*_{*t*} = *β*₁+*β*₂*x*_{*t*}+*ε*_{*t*}, при этом

ε

t

=

ρ

1

ε

t
−
1

+

ρ

2

ε

t
−
2

+
.
.
.
+

ρ

p

ε

t
−
p

+

u

t

{\displaystyle \varepsilon _{t}=\rho _{1}\varepsilon _{t-1}+\rho _{2}\varepsilon _{t-2}+\ldots +\rho _{p}\varepsilon _{t-p}+u_{t}}

 Гипотеза выглядит следующим образом:

*H*₀ : *ρ*₁ = ... = *ρ*_{*p*} = 0 (автокорреляции в остатках нет)

*H*_{*a*} : ∃*ρ*_{*j*} ≠ 0, *j* = 1 ... *T* (автокорреляция есть)

Шаг 1. Оценивается начальная модель и рассчитывается ряд остатков.

Шаг 2. Оценивается дополнительная модель:

e

t

=

β

1

+

β

2

x

t

+

r

1

e

t
−
1

+

r

2

e

t
−
2

+
.
.
.
+

r

p

e

t
−
p

+

u

t

{\displaystyle e_{t}=\beta _{1}+\beta _{2}x_{t}+r_{1}e_{t-1}+r_{2}e_{t-2}+\ldots +r_{p}e_{t-p}+u_{t}}

Шаг 3. Для дополнительной модели рассчитывается *R*_{*e*}², а затем стати-стика вида:

χ

2

=
T
×

R

e

2

∼

χ

p

2

{\displaystyle \chi ^{2}=T\times R_{e}^{2}\sim \chi _{p}^{2}}

Если значение статистики превышает критическое при выбранном уровне значимости, основная гипотеза об отсутствии автокорреляции отвергается.

11.3 Что делать, если обнаружилась автокорреляция?

- Переход к взвешенным разностям**. Пусть модель выглядит как *y*_{*t*} = *β*₁ + *β*₂*x*_{*t*} + *ε*_{*t*}.
Шаг 1. Необходимо получить оценку параметра *ρ*. Например, можно оценить его из статистики Дарбина-Уотсона по формуле *ρ̂* = 1 − *d̂*/₂.
Шаг 2. Далее исходное уравнение сдвигается на шаг назад и домножа-ется на *ρ*:

ρ

y

t
−
1

=
ρ

β

1

+
ρ

β

2

x

t
−
1

+

ε

t
−
1

{\displaystyle \rho y_{t-1}=\rho \beta _{1}+\rho \beta _{2}x_{t-1}+\varepsilon _{t-1}}

Шаг 3. Вычсть из исходного уравнения преобразованное. Получаем:

y

t

−
ρ

y

t
−
1

=

β

1

(
1
−
ρ
)
+

β

2

(

x

t

−
ρ

x

t
−
1

)
+

ε

t

−
ρ

ε

t
−
1

{\displaystyle y_{t}-\rho y_{t-1}=\beta _{1}(1-\rho)+\beta _{2}(x_{t}-\rho x_{t-1})+\varepsilon _{t}-\rho \varepsilon _{t-1}}

Теперь автокорреляция отсутствует, но теряется одно наблюдение.

- Поправка Прайса - Уинстона**. Заменяем первые наблюдения:

y

1

∗
=

y

1

√
1
−

ρ

2

,

x

1

∗
=

x

1

√
1
−

ρ

2

{\displaystyle y_{1}^{*}=y_{1}{\sqrt {1-\rho ^{2}}},\quad x_{1}^{*}=x_{1}{\sqrt {1-\rho ^{2}}}}

12.0 Временные ряды

Временной ряд — ряд некоторых числовых величин, измеренных в последовательные моменты времени.
 { y t } + ∞<!-- ∞ --> −<!-- − --> ∞<!-- ∞ --> , t = 1 . . . T {\displaystyle \{y_{t}\}_{-\infty }^{+\infty },\,t=1\ldots T}

Ключевым отличием временных рядов от пространственных выборок яв-ляется то, что наблюдения строго упорядочены по времени, невозможно произвольно менять их местами, а также выкидывать из выборки.

12.1 Стационарные процессы

Утверждение 12.1 { y t } {\displaystyle \{y_{t}\}} называется стационарным в узком смыс-ле, если распределение <i>y</i> ₁₁ , <i>y</i> ₁₂ , <i>y</i> ₁₃ , ..., <i>y</i> _{1<i>k</i>} совпадает с распределением <i>y</i> _{11+<i>s</i>} , <i>y</i> _{12+<i>s</i>} , <i>y</i> _{13+<i>s</i>} , ..., <i>y</i> _{1<i>k</i>+<i>s</i>} ∀<!-- ∀ --> t 1 . . . t k + s , s > 0 , k > 0 {\displaystyle \ \ \forall t_{1}\ldots t_{k+s},\,s>0,k>0}

Утверждение 12.2 { y t } {\displaystyle \{y_{t}\}} называется стационарным в широком смысле, если:
 E (y t) = μ<!-- μ --> {\displaystyle \mathrm {E} (y_{t})=\mu }
 Var (y t) = σ<!-- σ --> 2 {\displaystyle \mathrm {Var} (y_{t})=\sigma ^{2}}
 Cov (y t , y t −<!-- − --> k) = Cov (y t + s , y t −<!-- − --> k + s) = γ<!-- γ --> (k) {\displaystyle \mathrm {Cov} (y_{t},y_{t-k})=\mathrm {Cov} (y_{t+s},y_{t-k+s})=\gamma (k)}

Стационарный временной ряд — это такой ряд, который не меняется со временем с каким-либо трендом, то есть не растет и не снижается. Фор-мально это означает, что математическое ожидание стационарного вре-менного ряда — постоянно, равно как и его дисперсия, а его значения на равном расстоянии друг от друга связаны одинаково.

12.2 Процессы AR, MA, ARMA и ARIMA

Определение 12.0 Белый шум <i>y</i> _{<i>t</i>} ~ <i>WN</i> (0, <i>σ</i> ²) — слабо стационарный процесс, обладающий следующими свойствами:
 E (y t) = E (y s) = 0 {\displaystyle \mathrm {E} (y_{t})=\mathrm {E} (y_{s})=0}
 Var (y t) = Var (y s) = σ<!-- σ --> 2 {\displaystyle \mathrm {Var} (y_{t})=\mathrm {Var} (y_{s})=\sigma ^{2}}
 Cov (y t , y s) = 0 {\displaystyle \mathrm {Cov} (y_{t},y_{s})=0}

Определение 12.1 <i>AR</i> (<i>p</i>) — процесс, зависящий только от своих предыдущих значений и ошибки в текущий момент времени:
 y t = c + α<!-- α --> 1 y t −<!-- − --> 1 + α<!-- α --> 2 y t −<!-- − --> 2 + . . . + α<!-- α --> p y t −<!-- − --> p + ε<!-- ε --> t = c + ∑<!-- ∑ --> i = 1 p α<!-- α --> i y t −<!-- − --> i + ε<!-- ε --> t {\displaystyle y_{t}=c+\alpha _{1}y_{t-1}+\alpha _{2}y_{t-2}+\ldots +\alpha _{p}y_{t-p}+\varepsilon _{t}=c+\sum _{i=1}^{p}\alpha _{i}y_{t-i}+\varepsilon _{t}}
 t = 1 , . . . , T ; ε<!-- ε --> t ∼<!-- ∼ --> W N (0 , σ<!-- σ --> 2) {\displaystyle t=1,\ldots ,T;\quad \varepsilon _{t}\sim WN(0,\sigma ^{2})}

Определение 12.2 <i>MA</i> (<i>q</i>) — процесс, зависящий только от лагов слу-чайной ошибки:
 y t = c + ε<!-- ε --> t + β<!-- β --> 1 ε<!-- ε --> t −<!-- − --> 1 + . . . + β<!-- β --> q ε<!-- ε --> t −<!-- − --> q = c + ∑<!-- ∑ --> i = 1 q β<!-- β --> i ε<!-- ε --> t −<!-- − --> i + ε<!-- ε --> t {\displaystyle y_{t}=c+\varepsilon _{t}+\beta _{1}\varepsilon _{t-1}+\ldots +\beta _{q}\varepsilon _{t-q}=c+\sum _{i=1}^{q}\beta _{i}\varepsilon _{t-i}+\varepsilon _{t}}
 t = 1 , . . . , T ; ε<!-- ε --> t ∼<!-- ∼ --> W N (0 , σ<!-- σ --> 2) {\displaystyle t=1,\ldots ,T;\quad \varepsilon _{t}\sim WN(0,\sigma ^{2})}

Определение 12.3 <i>ARMA</i> (<i>p</i> , <i>q</i>) — процесс, зависящий и от своих предыдущих значений, и от текущей и предыдущих ошибок:
 y t = c + ∑<!-- ∑ --> i = 1 p α<!-- α --> i y t −<!-- − --> i + ∑<!-- ∑ --> j = 1 q β<!-- β --> j ε<!-- ε --> t −<!-- − --> j + ε<!-- ε --> t {\displaystyle y_{t}=c+\sum _{i=1}^{p}\alpha _{i}y_{t-i}+\sum _{j=1}^{q}\beta _{j}\varepsilon _{t-j}+\varepsilon _{t}}
 t = 1 , . . . , T ; ε<!-- ε --> t ∼<!-- ∼ --> W N (0 , σ<!-- σ --> 2) {\displaystyle t=1,\ldots ,T;\quad \varepsilon _{t}\sim WN(0,\sigma ^{2})}

Как выбрать оптимальное число лагов? Можно использовать информа-ционные критерии Акаике (AIC) и Шварца (BIC):

A
I
C
(
p
,
q
)
=
ln
⁡
σ

2

+
2

p
+
q
+
1

T

→

min

p
,
q

{\displaystyle AIC(p,q)=\ln {\hat {\sigma }}^{2}+2{\frac {p+q+1}{T}}\longrightarrow \min _{p,q}}

B
I
C
(
p
,
q
)
=
ln
⁡
σ

2

+

p
+
q
+
1

T

ln
⁡
T
→

min

p
,
q

{\displaystyle BIC(p,q)=\ln {\hat {\sigma }}^{2}+{\frac {p+q+1}{T}}\ln T\longrightarrow \min _{p,q}}

Также можно провести тесты Льюнг - Бокса и Бокса - Пирса. Оба проверяют следующую гипотезу:

*H*₀ : процесс - *WN*(0, *σ*²)

*H*_{*a*} : процесс - *ARMA*(*p*, *q*)

1. Q-тест Льюнг - Бокса. Статистика рассчитывается как:

Q

k

=
T
(
T
+
2
)
∑

k
=
1

K

1

T
−
K

r

k

2

∼

χ

K
−
p
−
q
−
1

2

{\displaystyle Q_{k}=T(T+2)\sum _{k=1}^{K}{\frac {1}{T-K}}r_{k}^{2}\sim \chi _{K-p-q-1}^{2}}

2. Q-статистика Бокса - Пирса. Статистика рассчитывается как:

Q

k

=
T
∑

k
=
1

K

r

k

2

∼

χ

K
−
p
−
q
−
1

2

{\displaystyle Q_{k}=T\sum _{k=1}^{K}r_{k}^{2}\sim \chi _{K-p-q-1}^{2}}

В обоих случаях, если при выбранном уровне значимости величина стати-стики превышает критическое значение, основная гипотеза отвергается.

Определение 12.4 Если для некоторого ряда <i>y</i> _{<i>t</i>} необходимо взять <i>d</i> разностей, чтобы привести его к стационарному виду, а ряд <i>Δy</i> _{<i>t</i>} описывается моделью <i>ARMA</i> (<i>p</i> , <i>q</i>), то ряд <i>y</i> _{<i>t</i>} описывается моделью <i>ARIMA</i> (<i>p</i> , <i>d</i> , <i>q</i>).

12.3 Тест Дики - Фуллера на стационарность ряда

Для начала необходимо привести исходный ряд к виду *Δy*_{*t*} = *δ* + *γt* + (*θ* − 1)*y*_{*t*−1} + *ε*_{*t*}, где *δ* — константа, а *γt* отвечает за тренд. Гипотеза формулируется как:

*H*₀ : *θ* − 1 = 0 - ряд нестационарный

*H*_{*a*} : *θ* − 1 < 0 - ряд стационарный

При этом предполагается, что *ε*_{*i*} ~ *N*(0, *σ*²). Тестовая статистика (DF-статистика) рассчитывается по формуле, анало-гичной с формулой t-статистики на значимость коэффициента:

D
F
=

θ
−
1

√
Var
⁡
(
θ
−
1
)

{\displaystyle DF={\frac {\hat {\theta }-1}{\sqrt {\hat {\mathrm {Var} }(\theta -1)}}}

У статистики Дики-Фуллера своя таблица критических значений и свое распределение, если тестовая статистика находится правее критического значения, то нулевая гипотеза отвергается. При этом критическое значе-ние рассчитывается исходя из спецификации теста:

- Без константы;
- С константой;
- С константой и трендом.

12.4 Ложная корреляция и коинтеграция

Ложная корреляция — эффект, при котором между двумя переменными наблюдается значимая корреляция, при этом отсутствует качественная причинно-следственная связь. Может возникать из-за того, что обе переменные являются нестационарными, и в них обеих наблюдается стохастический тренд.

Коинтеграция — свойство нескольких нестационарных временных рядов, заключающееся в существовании некоторой их стационарной линейной комбинации.

Говорят, что нестационарный ряд является интегрированным порядка d , если необходимо взять d разностей, чтобы его к стационарному виду. Такие ряды означаются как $I(d)$.

Рассмотрим два нестационарных ряда: $y_t \sim I(d)$ и $x_t \sim I(d)$, где $I(d)$. Если существует такой вектор $(\alpha, \beta) : \alpha \neq 0, \beta \neq 0$, что $\alpha y_t + \beta x_t \sim I(d - b), b > 0$, то ряды называются *коинтегрированными* порядка b .