

Эконометрика, НИУ ВШЭ

Составили эконометрессы Максимовская Анастасия, Перевышина Татьяна, Ситникова Арина, а также Пилипейко Роман

1.0 Линейная регрессия с одной объясняющей переменной (парная регрессия)


Линейная регрессионная модель имеет следующий вид:

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i, \quad i = 1, ..., n$$

1.1 Метод наименьших квадратов (OLS) для нахождения оценок коэффициентов парной регрессии

Зачем он нужен? Для нахождения оценок коэффициентов  $\hat{\beta}_1, \hat{\beta}_2$

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i$$
$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$$
$$\hat{\beta}_2 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{sCov(x, y)}{sVar(x)}$$



$$sCorr(x; y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Проекция  $y$  на  $Lin(1; x)$ :  $\hat{y} = \hat{\beta}_1 \mathbb{1} + \hat{\beta}_2 x^c$

Проекция  $x$  и  $y$  на  $Lin\perp(\mathbb{1})$ :  $x^c = x - \bar{x}\mathbb{1} = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}, y^c = y - \bar{y}\mathbb{1} = \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}$

Проекция  $x$  и  $y$  на  $Lin\perp(\mathbb{1})$ :  $x^c = x - \bar{x}\mathbb{1} = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}$

Проекция  $y^c$  на  $Lin(x^c)$ :  $\beta_2 x^c = \hat{y} - \bar{y}\mathbb{1}$

Проекция  $x^c$  на  $Lin(\mathbb{1})$ : 0

Проекция  $x^c$  на  $Lin\perp(\mathbb{1})$ :  $x^c$

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2 = ESS + RSS = |y - \bar{y}\mathbb{1}|^2 = AB^2 = y^c{}^2$$
$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = AC^2$$
$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2 = BC^2$$
$$R^2 = \frac{ESS}{TSS} = \frac{sVar(\hat{y})}{sVar(y)} = \frac{AC^2}{AB^2} = \cos(\varphi') = sCorr^2(y; \hat{y}) = sCorr^2(y; x)$$

1.2 Теорема Гаусса - Маркова для случая парной регрессии

Зачем она нужна? Для получения дополнительной информации о характеристиках распределения оценок  $\hat{\beta}_1, \hat{\beta}_2$

**Теорема 1.2 Гаусса - Маркова для случая парной регрессии**

Если для модели  $\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_i + \varepsilon_i, i = 1, ..., n$  выполняются следующие условия:

- 1) Строится регрессия  $y$  на  $x$
- 2) Не все  $x_i$  равны между собой
- 3) Математическое ожидание от любой ошибки регрессии равно 0
- 4) Дисперсия от любой ошибки регрессии равна  $\sigma_\varepsilon^2$
- 5)  $Cov(\varepsilon_i, \varepsilon_j) = 0$  - отсутствие автокорреляции,

то МНК - оценки  $\hat{\beta}_1$  и  $\hat{\beta}_2$  являются *BLUE*

Best (наилучшие)	для любых $\hat{\beta}_i$ верно: $MSE(\hat{\beta}_i) \leq MSE(\beta_i)$
Linear (линейные)	Оценки линейные по $y$
Unbiased (несмещенные) Estimator (оценки)	$E(\hat{\beta}_i) = \beta_i$

**Утверждение 1.2** Если условия теоремы Гаусса - Маркова выполнены, то дисперсии МНК оценок:

$$Var(\hat{\beta}_1) = \sigma_\varepsilon^2 \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \quad Var(\hat{\beta}_2) = \frac{\sigma_\varepsilon^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

а их ковариация:

$$Cov(\hat{\beta}_1, \hat{\beta}_2) = -\frac{\bar{x} \sigma_\varepsilon^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}$$

1.3 Предположение о нормальном распределении случайной ошибки в рамках классической линейной регрессии

**Утверждение 1.3.1** Если верно, что  $\varepsilon_i \sim N(0, \sigma_\varepsilon^2), i = 1...n$ , то МНК-оценки коэффициентов парной регрессии также имеют нормальное распределение, причём  $\hat{\beta}_1 \sim N(\beta_1, Var(\hat{\beta}_1)), \hat{\beta}_2 \sim N(\beta_2, Var(\hat{\beta}_2))$ .

**Утверждение 1.3.2**  $\hat{\sigma}_\varepsilon^2 = \frac{RSS}{n-2}$  является несмещённой оценкой для  $\sigma_\varepsilon^2$ .

**Утверждение 1.3.3**  $\frac{RSS}{\hat{\sigma}_\varepsilon^2} \sim \chi_{n-2}^2$  для парной регрессии.

**Утверждение 1.3.4** Оценки  $\hat{\beta}_1$  и  $\hat{\sigma}_\varepsilon^2, \hat{\beta}_2$  и  $\hat{\sigma}_\varepsilon^2$  являются независимыми.

1.3.1 Проверка гипотезы о конкретном значении коэффициентов парной регрессии

$$H_0 : \beta_2 = \beta_2^0$$
$$H_a : \beta_2 \neq \beta_2^0$$

Если  $|t = \frac{\hat{\beta}_2 - \beta_2^0}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| > t^{cr}$  (при уровне значимости  $\alpha/2$  и  $n - 2$  степенях свободы), то гипотеза  $H_0$  отвергается в пользу гипотезы  $H_a$ .

Если значение  $|t = \frac{\hat{\beta}_2 - \beta_2^0}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| < t^{cr}$  (при уровне значимости  $\alpha/2$  и  $n - 2$  степенях свободы), то гипотеза  $H_0$  не отвергается.

1.3.2 Проверка гипотезы о значимости коэффициентов парной регрессии

$$H_0 : \beta_2 = 0$$
$$H_a : \beta_2 \neq 0$$

Если значение  $|t = \frac{\hat{\beta}_2}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| > t^{cr}$  (при уровне значимости  $\alpha/2$  и  $n - 2$  степенях свободы), то гипотеза  $H_0$  отвергается, значит,  $\beta_2$  значим.

Если значение  $|t = \frac{\hat{\beta}_i}{\sqrt{\hat{Var}(\hat{\beta}_2)}}| < t^{cr}$  (при уровне значимости  $\alpha/2$  и  $n - 2$  степенях свободы), то гипотеза  $H_0$  не отвергается, значит,  $\beta_2$  не значим.

Доверительный интервал

$$[\hat{\beta}_2 - t^{cr} \sqrt{\hat{Var}(\hat{\beta}_2)}; \hat{\beta}_2 + t^{cr} \sqrt{\hat{Var}(\hat{\beta}_2)}]$$

Если доверительный интервал включает в себя нуль, то этот коэффициент не значим, при уровне значимости  $\alpha$ .

В обоих случаях  $t^{cr}$  рассчитывается на уровне значимости  $\alpha/2$  с  $n - 2$  степенями свободы.

1.3.3 Прогнозирование по модели парной регрессии и его точность

**Доверительный интервал для среднего прогноза**

$$\hat{Var}(\hat{y}_{n+1}) = \hat{Var}(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1}) = \hat{\sigma}_\varepsilon^2 [1 + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}]$$
$$P(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} - t_{\alpha/2, n-2} \sqrt{\hat{Var}(\hat{y}_{n+1})} \leq E(y_{n+1} | x = x_{n+1}) \leq \hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + t_{\alpha/2, n-2} \sqrt{\hat{Var}(\hat{y}_{n+1})}) = 1 - \alpha$$

**Доверительный интервал для индивидуального прогноза**

$$\hat{Var}(y_{n+1}) = \hat{Var}(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + \varepsilon_{n+1}) = \hat{\sigma}_\varepsilon^2 [1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}]$$
$$P(\hat{\beta}_1 + \hat{\beta}_2 x_{n+1} - t_{\alpha/2, n-2} \sqrt{\hat{Var}(y_{n+1})} \leq y_{n+1} \leq \hat{\beta}_1 + \hat{\beta}_2 x_{n+1} + t_{\alpha/2, n-2} \sqrt{\hat{Var}(y_{n+1})}) = 1 - \alpha$$

Доверительный интервал дисперсии ошибок регрессии

$$P(\frac{RSS}{\chi_{\alpha/2, n-2}^2} \leq \sigma_\varepsilon^2 \leq \frac{RSS}{\chi_{1-\alpha/2, n-2}^2}) = 1 - \alpha$$

1.3.4 Проверка гипотезы о нормальности распределения

Критерий Колмогорова - Смирнова

Когда используется? Выборка состоит из достаточно большого количества наблюдений  $n$

$$H_0 : F(t) = G(t) \text{ для любого } t$$
$$H_a : F(t) \neq G(t) \text{ при некотором } t$$

С использованием таблиц:


$$J = \frac{mn}{d} \max_{-\infty < t < \infty} |F_m(t) - G_n(t)|$$

где  $F_m(t)$  и  $G_m(t)$  – эмпирические функции распределения для выборок  $x_1, ..., x_m$  и  $y_1, ..., y_n$ , а именно:

$$F_m(t) = \frac{\text{Число элементов в первой выборке, не превышающих } t}{m}$$
$$G_n(t) = \frac{\text{Число элементов во второй выборке, не превышающих } t}{n}$$

$d$  – НОД( $m, n$ ),  $m$  и  $n$  – общее количество элементов в первой и второй выборке соответственно.

Статистика имеет специальное распределение  $D$  при верной  $H_0$ :



**Тест Харке - Бера** Когда используется? Выборка состоит из достаточно большого количества наблюдений  $n$

$$H_0 : s = 0, k = 3$$
$$H_a : s \neq 0, k \neq 3$$

Тестовая статистика:

$$JB = \frac{n}{6} (s^2 + \frac{1}{4} (k - 3)^2) \sim \chi_2^2$$

Коэффициент асимметрии:  $s = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^3}{\bar{\sigma}^3}, \bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

Для симметричных распределений, в том числе нормального, этот показатель равен нулю.

Коэффициент эксцесса:  $k = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})^4}{\bar{\sigma}^4}$

Для нормального распределения этот показатель равен 3.

Если  $JB > \chi_2^2$  при выбранном уровне значимости, то гипотеза отвергается.

Тест Шапиро - Уилка

Когда используется? Выборка состоит из небольшого количества наблюдений  $n$

$$H_0 : x_1, ..., x_n - \text{выборка из нормального распределения}$$
$$H_a : x_1, ..., x_n - \text{выборка не из нормального распределения}$$

Тестовая статистика:

$$W = \frac{(\sum_{i=1}^n \alpha_{(i)} x_i)^2}{\sum_{i=1}^n (x_{(i)} - \bar{x})^2} \sim W_\alpha$$

Вектор коэффициентов:  $\alpha_{(i)} = \frac{m^T V^{-1}}{m^T V^{-1} V^{-1} m}$

$m$  – вектор математических ожиданий порядковых статистик нормального распределения;  
 $V$  – ковариационная матрица этих порядковых статистик размера  $n \times n$ .

Для небольших  $n$  коэффициенты  $\alpha_{(i)}$  берутся из таблиц.

Если  $W < W_\alpha$ , то гипотеза  $H_0$  отвергается.











4. Вычисляем тестовую статистику:

$$\chi^2 = nR_e^2 \sim \chi_{m-1}^2$$

где *m* – число оцениваемых во вспомогательной регрессии коэффициентов.

5. Если Р-значение < α, гипотеза *H*<sub>0</sub> о гомоскедастичности отвергается.

Эта же гипотеза (о равенстве нулю всех коэффициентов α<sub>*i*</sub>, γ<sub>*i*</sub>, δ<sub>*ij*</sub>) может быть проверена с помощью *F*-статистики. Если значение тестовой статистики превышает критическое, то нулевая гипотеза о гомоскедастичности отвергается.

- Тест Бройша - Пагана**

Привлекательной чертой теста Уайта является его универсальность, однако он не дает указания на функциональную форму гетероскедастичности. Если может иметь место и более специфический вид зависимости, в том числе и от не включенных в модель факторов *z*<sub>1</sub>, ..., *z*<sub>*p*</sub>, используют тест Бройша - Пагана. Альтернативная гипотеза для него имеет вид:

$$H_a: \sigma_i^2 \sim f(z_1, ..., z_p)$$

причем *f* предполагается некоторой гладкой функцией, но ее вид не конкретизируется.

Тест Бройша - Пагана состоит из следующих шагов (первые два шага совпадают с предыдущими тестами):

3. Строим оценку для дальнейшей нормировки квадратов остатков регрссии:

$$\hat{\sigma}_i^2 = \frac{\sum_{i=1}^k e_i^2}{n}.$$

4. Оцениваем параметры регрессии

$$\frac{e_i^2}{\hat{\sigma}_i^2} = \gamma_1 + \gamma_2 z_{i2} + ... + \gamma_p z_{ip} + \varepsilon_i$$

и вычисляем для нее *ESS*.

5. Рассчитываем тестовую статистику:

$$\chi^2 = \frac{ESS}{2} \sim \chi_p^2$$

6. Если Р-значение < α, гипотеза *H*<sub>0</sub> о гомоскедастичности отвергается.

#### 7.2 Оценивание параметров множественной линейной регрессии в условиях гетероскедастичности ошибок

- Изменение модели с линейной формы на логарифмическую может привести к тому, что в тестах на гетероскедастичность не будет отвергаться основная гипотеза о гомоскедастичности.

- Если дисперсии всех ошибок заранее известны, то для устранения гетероскедастичности достаточно было бы оценить исходное уравнение, поделенное почленно на стандартные отклонения ошибок

$$\frac{y_i}{\sigma_i} = \beta_1 \frac{1}{\sigma_i} + \beta_2 \frac{x_{i2}}{\sigma_i} + ... + \beta_k \frac{x_{ik}}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}, i = 1, ..., n$$

и оценить регрессию с новыми факторами

$$y_i^* = \frac{y_i}{\sigma_i}, 1_i^* = \frac{1}{\sigma_i}, x_{ij}^* = \frac{x_{ij}}{\sigma_i}, \varepsilon_i^* = \frac{\varepsilon_i}{\sigma_i}, j = 1, .., k, i = 1, ..., n$$

В уравнении *y*<sub>*i*</sub><sup>\*</sup> = β<sub>1</sub>1<sub>*i*</sub><sup>\*</sup> + β<sub>2</sub>*x*<sub>*i2*</sub><sup>\*</sup> + ... + β<sub>*k*</sub>*x*<sub>*ik*</sub><sup>\*</sup> + ε<sub>*i*</sub><sup>\*</sup> все ошибки имеют одну и ту же дисперсию, равную единице, поскольку Var(ε<sub>*i*</sub><sup>\*</sup>) = Var(



ε

i


σ

i




{\displaystyle {\frac {\varepsilon \_{i}}{\sigma \_{i}}}}

) = 






1


σ

i


2




{\displaystyle {\frac {1}{\sigma \_{i}^{2}}}}

 Var(ε<sub>*i*</sub>) = 1. Тогда МНК-оценки коэффициентов в регрессии с преобразованными данными имеют вид

$$\hat{\beta }^{*}=(X^{*T}X^{*})^{-1}(X^{*T}Y^{*})$$

Эту оценку можно выразить через исходные данные

$$\hat{\beta }^{*}=(X^{T}\Omega ^{-1}X)^{-1}(X^{T}\Omega ^{-1}Y)$$

$$\mathrm{где}\;\Omega =\left[ \begin{array}{ccc}\sigma _{1}^{2}& \ldots & 0\\ 0& \ldots & 0\\ 0& \ldots & \sigma _{n}^{2}\end{array}\right]$$

Данная оценка называется оценкой **взвешенного МНК**. Ковариационная матрица оценок имеет вид *V*(β
^
) = (*X*<sup>*T*</sup>Ω<sup>−1</sup>*X*)<sup>−1</sup>

- Наиболее распространенным способом коррекции гетероскедастичности в общем виде является использование оценок Уайта для дисперсий коэффициентов:

$$\hat{V}(\hat{\beta})=\frac{1}{n}(\frac{1}{n}X^TX)^{-1}(\frac{1}{n}\sum_{i=1}^ne_i^2x_ix_i^T)(\frac{1}{n}X^TX)^{-1}$$

где *x<sub>i</sub>* – i-я строка матрицы *X*, *i* = 1, ..., *n*

- Для выявления гетероскедастичности рекомендуется проверить выборку на наличие вертикальных выбросов.

- Можно также рассмотреть стандартизированные остатки в двух формах:

$$e_i^*=\frac{e_i}{\hat{\sigma}_{\varepsilon}\sqrt{1-h_{ii}}}$$

$$e_i^*=\frac{e_i}{\hat{\sigma}_{\varepsilon(-i)}\sqrt{1-h_{ii}}},$$

где *e* = (*I* − *H*)ε,

*H* = *X*(*X*<sup>*'*</sup>*X*)<sup>−1</sup>*X*<sup>*'*</sup> – матрица-шляпница,

Y
^


=
H
Y
,


{\displaystyle {\hat {Y}}=HY,}

y

i


=

∑

i
=
1


n



h

i
i



y

i


,


h

i
i


 – диагональный элемент *h*,

Var(*e*) = (*I* − *H*)σ<sub>ε</sub><sup>2</sup>.

Если |*e*<sub>*i*</sub><sup>\*</sup>| > 2, то это выброс.

При обнаружении выбросов можно:

- Оценить без них;
- Создать фиктивную переменную на выброс;
- Применить робастное (устойчивое к выбросам) оценивание.

В чем заключается робастное оценивание?

Медианная регрессия: 



R
S
S
=

∑

i
=
1


n



|

e

i


|
→
min

β




{\displaystyle RSS=\sum \_{i=1}^n|e\_{i}|\rightarrow \min \_{\beta }}

Р-регрессия: 



ρ
{



ε

i


σ

i




}
→
min


{\displaystyle \rho \{\frac {\varepsilon \_{i}}{\sigma \_{i}}\}\rightarrow min}

 тождественно равно 



∑

i
=
1


n



w

i



e

i


2


→
min


{\displaystyle \sum \_{i=1}^nw\_{i}e\_{i}^{2}\rightarrow min}

Функция потерь Хьюбера:

$$\rho (u)=\left\{\begin{array}{l}\frac{1}{2}u^2,|u|\leq c,\\c|u|-\frac{1}{2}c^2,|u|>c\end{array}\right.$$

Веса корректируются на каждом шаге по формуле *u<sub>i</sub>* = 






1




ε

i


2




ρ
(



ε

i


σ

i




)


{\displaystyle {\frac {1}{\varepsilon \_{i}^{2}}}\rho ({\frac {\varepsilon \_{i}}{\sigma \_{i}}})}

. Корректировка заканчивается, когда веса почти не меняются. Берутся последние значения β.

### 8.0 Метод максимального правдоподобия

Метод максимального правдоподобия, в отличие от МНК, работает при более слабых предположениях, чем выполнение условий ТГМ. Если *x*<sub>1</sub>, ..., *x<sub>n</sub>* – реализации случайных величин *X*<sub>1</sub>, ..., *X<sub>n</sub>*, то необходимо максимизировать функцию правдоподобия:

$$L(x_1,...,x_n|\theta )=P(X_1=x_1,...,X_n=x_n|\theta )\rightarrow max_{\theta },$$

где **θ** – вектор оцениваемых параметров.

Однако на практике чаще ищут максимум логарифмической функции правдоподобия:

$$l(x_1,...,x_n|\theta )=lnL(x_1,...,x_n|\theta )$$

Для случая непрерывных величин *X*<sub>1</sub>, ..., *X<sub>n</sub>* в качестве функции правдоподобия выбирается плотность их совместного распределения в точке *x*<sub>1</sub>, ..., *x<sub>n</sub>*:

$$L(x_1,...,x_n|\theta )=f(x_1,...,x_n|\theta )$$

#### 8.1 Свойства МL-оценок

1. Инвариантность

Если 




θ

ML




{\displaystyle \theta \_{ML}}

 – МL-оценка параметра **θ** и *g*(·) – непрерывная функция, то *g*(




θ

ML




{\displaystyle \theta \_{ML}}

) является МL-оценкой параметра *g*(**θ**).

2. Состоятельность

3. Асимптотическая нормальность

При *n* → ∞ оценка вектора параметров имеет нормальное распределение:

$$\hat{\theta }_{ML}\overset{as}{\approx }N(\theta ;I^{-1}(\theta )),$$

где *I*(**θ**) – информационная матрица Фишера.

4. Асимптотическая эффективность

#### 8.2 Проверка гипотез

Следующие три теста позволяют проверить гипотезу об ограничениях:

$$H_0:\left\{\begin{array}{l}g_1(\theta )=0\\...\\g_r(\theta )=0\end{array}\right.$$

$$H_a:\left\{\begin{array}{l}g_1(\theta )\neq 0\\...\\g_r(\theta )\neq 0\end{array}\right.$$

- Тест Вальда

$$W=g^T(\hat{\theta }_{ur})[\frac{\partial g}{\partial \theta }(\hat{\theta }_{ur})I^{-1}(\hat{\theta }_{ur})\frac{\partial g^T}{\partial \theta }(\hat{\theta }_{ur})]^{-1}g(\hat{\theta }_{ur})\sim \chi _r^2$$

- Тест отношения правдоподобия (LR-тест)

$$LR=-2(l(\hat{\theta }_r)-l(\hat{\theta }_{ur}))\sim \chi _r^2$$

- Тест множителей Лагранжа (LM-тест)

$$LM=\frac{\partial l}{\partial \theta }(\hat{\theta }_r)^TI^{-1}(\hat{\theta }_r)\frac{\partial l}{\partial \theta }(\hat{\theta }_r)\sim \chi _r^2$$

Во всех случаях *r* – количество ограничений.

#### 9.0 Модели бинарного выбора

В случаях, когда объясняемая переменная *y* – бинарная (принимает значения 0 или 1), также можно использовать линейную модель *y<sub>i</sub>* = β<sub>1</sub> + β<sub>1</sub>*x*<sub>*i2*</sub> + ... + β<sub>*k*</sub>*x*<sub>*ik*</sub> + ε<sub>*i*</sub>.

Пусть *p<sub>i</sub>* = *P*(*y<sub>i</sub>* = 1), *i* = 1, ..., *n*. Тогда *P*(*y<sub>i</sub>* = 0) = 1 − *p<sub>i</sub>* и верно, что *E*(*y<sub>i</sub>*) = *P*(*y<sub>i</sub>* = 1) × 1 + *P*(*y<sub>i</sub>* = 0) × 0. При этом также верно, что *E*(*y<sub>i</sub>*) = β<sub>1</sub> + β<sub>2</sub>*x*<sub>*i2*</sub> + ... + β<sub>*k*</sub>*x*<sub>*ik*</sub>. Отсюда получается модель линейной вероятности:

$$P(y_i=1)=\beta _1+\beta _2x_{i2}+...+\beta _kx_{ik}$$

Недостатки модели линейной вероятности

- Оцененное значение вероятности может не принадлежать отрезку [0; 1].
- Ошибки не будут распределены нормально, т.к. ε<sub>*i*</sub> тоже принимает значения 0 или 1. Следовательно, привычные *t*-статистики для проверки гипотез использовать нельзя.
- Дисперсии ошибок равны

(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)
(
1
−
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)
)
,
i
=
1
,
...
,
n
,


{\displaystyle (\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik})(1-(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik})),i=1,...,n,}

т.е. имеет место гетероскедастичность, МНК-оценки не будут эффективными.

#### 9.1 Логит и пробит модели

Для исправления данных недостатков используют модели бинарного выбора:

$$P(y_i=1)=F(z_i),\quad z_i=\beta _1+\beta _2x_{i2}+...+\beta _kx_{ik},\quad i=1,...,n,$$

где *F* – сигмоидная функция, принимающая значения на интервале [0;1]. Предположим, что существует *y<sub>i</sub><sup>\*</sup>* = β<sub>1</sub> + β<sub>2</sub>*x*<sub>*i2*</sub> + ... + β<sub>*k*</sub>*x*<sub>*ik*</sub> + ε<sub>*i*</sub>, *i* = 1, ..., *n*, где ошибки ε<sub>*i*</sub>, ..., ε<sub>*n*</sub> независимы и имеют одну и ту же симметричную функцию плотности *f*(*x*) = *f*(−*x*), функцию распределения *F*(·), *E*(ε<sub>*i*</sub>) = 0, *Var*(ε<sub>*i*</sub>) = σ<sub>ε</sub><sup>2</sup>.

Величины *y<sub>i</sub>* и *y<sub>i</sub><sup>\*</sup>* связаны следующим образом:

$$\left\{\begin{array}{l}y_i=1,y_i^*\geq 0,\\y_i=0,y_i^*<0.\end{array}\right.$$

Тогда *P*(*y<sub>i</sub>* = 1) = *P*(*y<sub>i</sub><sup>\*</sup>* ≥ 0) = *P*(β<sub>1</sub> + β<sub>2</sub>*x*<sub>*i2*</sub> + ... + β<sub>*k*</sub>*x*<sub>*ik*</sub> + ε<sub>*i*</sub> ≥ 0) = = *P*(ε<sub>*i*</sub> ≥ −(β<sub>1</sub> + β<sub>2</sub>*x*<sub>*i2*</sub> + ... + β<sub>*k*</sub>*x*<sub>*ik*</sub>)).

В силу симметрии функции плотности *f* относительно нуля

$$P(y_i=1)=P(\varepsilon _i\leq \beta _1+\beta _2x_{i2}+...+\beta _kx_{ik})$$

Обозначим за *F*(·) функцию распределения нормированных ошибок 






ε

i


σ

ε





{\displaystyle {\frac {\varepsilon \_{i}}{\sigma \_{\varepsilon }}}

. Отсюда можно выразить формулу для моделей бинарного выбора:

$$P(y_i=1)=F(\frac {\beta _1}{\sigma _{\varepsilon }}+\frac {\beta _2}{\sigma _{\varepsilon }}x_{i2}+...+\frac {\beta _k}{\sigma _{\varepsilon }}x_{ik})$$

Наиболее употребимые в эконометрических моделях функции:

- Логит-модель

F
(
z
)
=


1


1
+

e

−
z




{\displaystyle F(z)={\frac {1}{1+e^{-z}}}}

 – логистическая функция

f
(
z
)
=



e

−
z



(
1
+

e

−
z

)

2





{\displaystyle f(z)={\frac {e^{-z}}{(1+e^{-z})^{2}}}}
- Пробит-модель

F
(
z
)
=



1


2
π





∫

−
∞


z



e

−

t

2


/
2


d
t


{\displaystyle F(z)={\frac {1}{\sqrt {2\pi }}}\int \_{-\infty }^{z}e^{-t^{2}/2}dt}

f
(
z
)
=



1


2
π





e

−

z

2


/
2




{\displaystyle f(z)={\frac {1}{\sqrt {2\pi }}}e^{-z^{2}/2}}

#### 9.2 Оценивание параметров моделей бинарного выбора

Для оценки параметров моделей бинарного выбора используется ММП. Функция правдоподобия выглядит следующим образом:

L
(
β
)
=

∏

y

i
=
1



F
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)

∏

y

i
=
0



(
1
−
F
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)
)
=

∏

i
=
1


n



(
F
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)

)

y

i




(
1
−
F
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)

)

1
−

y

i





{\displaystyle L(\beta )=\prod \_{y\_{i}=1}F(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik})\prod \_{y\_{i}=0}(1-F(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik}))=\prod \_{i=1}^n(F(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik}))^{y\_{i}}(1-F(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik}))^{1-y\_{i}}}

Логарифмическая функция правдоподобия:

l
(
β
)
=
ln
L
(
β
)
=

∑

i
=
1


n



[

y

i


ln
F
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)
+
(
1
−

y

i


)
ln
(
1
−
F
(

β

1


+

β

2


x

i
2


+
...
+

β

k


x

i
k


)
)
]


{\displaystyle l(\beta )=lnL(\beta )=\sum \_{i=1}^n[y\_{i}lnF(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik})+(1-y\_{i})ln(1-F(\beta \_{1}+\beta \_{2}x\_{i2}+...+\beta \_{k}x\_{ik}))]}

Если *F*(*z*) = Λ(*z*) = 






1


1
+

e

−
z




{\displaystyle {\frac {1}{1+e^{-z}}}}

, то для логит-моделей можно вывести следующую формулу:

$$\sum _{i=1}^n[y_{i}-\Lambda (\beta _{1}+\beta _{2}x_{i2}+...+\beta _{k}x_{ik})]x_{ij}=0,\quad j=0,...,k$$

#### 9.3 Интерпретация результатов оценивания логит- и пробит- моделей

При использовании ММП дисперсии оценок параметров являются соответствующими диагональными элементами матрицы *I*<sup>−1</sup>(**θ**). Для моделей бинарного выбора можно проверить гипотезу:

$$H_0:\beta _j=0$$

$$H_a:\beta _j\neq 0$$

При 






θ
^


as


N
(
θ
;

I

−
1


(
θ
)
)


{\displaystyle {\hat {\theta }}\overset{as}{\approx }N(\theta ;I^{-1}(\theta ))}

 тестовая статистика рассчитывается как:

$$z={\frac {\hat {\beta }_{j}}{\sqrt {\mathrm {Var} (\beta _{j})}}}$$

Если |*z*| ≥ *z*<sub>α/2</sub>, где α - выбранный уровень значимости, то гипотеза *H*<sub>0</sub> о незначимости отвергается. Однако интерпретировать можно только знак оценки коэффициента (если 






β
^


j


>
0
,


{\displaystyle {\hat {\beta }}\_{j}>0,}

 то при увеличении *x<sub>j</sub>* вероятность







Рассмотрим два нестационарных ряда:  $y_t \sim I(d)$  и  $x_t \sim I(d)$ , где  $I(d)$ . Если существует такой вектор  $(\alpha, \beta) : \alpha \neq 0, \beta \neq 0$ , что  $\alpha y_t + \beta x_t \sim I(d-b), b > 0$ , то ряды называются *коинтегрированными* порядка  $b$ .